2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

CKD-NHANES 2021-2023: enfermedad renal crónica por estadios

Grupo 39

Campos Madarieta, Simón

Ferreyra, Axel

Fromm, Joaquín

10 de noviembre de 2026

1. Introducción

1.1. Origen de los datos

Los datos provienen del National Health and Nutrition Examination Survey (NHANES), ciclo agosto 2021 – agosto 2023 (ciclo «L»), una encuesta de salud y nutrición de los Estados Unidos conducida por el National Center for Health Statistics (NCHS) de los CDC [1]. La encuesta combina una entrevista en el hogar con un examen físico y de laboratorio en un centro móvil.

El archivo `CKD_NHANES_2021_2023.csv` es un conjunto derivado: une variables de varios archivos de NHANES (demografía, medidas corporales, presión arterial, bioquímica en sangre, orina y cuestionarios de diabetes y tabaquismo) y agrega tres variables calculadas de función renal (`egfr`, `ckd_stage` y `ckd_present`). Su nombre coincide con un conjunto publicado en Kaggle [2], que declara 36 variables contra las 29 de este archivo; no se pudo verificar si son la misma versión. La Tabla 1 resume la evidencia del origen, verificada contra la documentación oficial de NHANES [3].

Dato	Documentación de NHANES	Este archivo (sección de la notebook)
Participantes del ciclo	11.933	11.933 filas (2.2)
Edad codificada como 80 («80 años o más»)	525	525 (2.6.1)
Índice de pobreza codificado como 5 («5 o más»)	2.149	2.149 (2.6.4)
Índice de pobreza faltante	2.041	2.041 (2.6.4)
`egfr` calculada con CKD-EPI 2021 sin raza [4]	declarado en la metadata [5]	se reproduce exactamente (2.11.1)

Tabla 1: Evidencia del origen del archivo: cifras de la documentación de NHANES y del archivo, con la sección de la notebook en la que se verifica cada una.

Tres particularidades del diseño de NHANES condicionan todo el análisis:

- **Es una muestra compleja con pesos muestrales**, que el archivo no incluye: todo lo que se calcula describe a la muestra y no a la población de EE.UU.
- **Sobremuestreo por edad.** En este ciclo se dejó de sobremuestrear por raza/etnia e ingreso y se empezó a sobremuestrear por grupo de edad.
- **Baja tasa de respuesta.** Respondió la entrevista el 34,5 % de las personas seleccionadas y completó el examen el 25,6 % [6]. Según la documentación de NHANES [3], 3.073 participantes solo respondieron la entrevista y no tienen medidas corporales ni análisis.

1.2. Contexto clínico

La enfermedad renal crónica (CKD, *chronic kidney disease*) se define por alteraciones de la estructura o de la función de los riñones presentes durante al menos tres meses. Se evalúa con dos ejes:

- **Filtrado (eGFR).** No se mide directamente: se estima a partir de la creatinina en sangre, la edad y el sexo con la ecuación CKD-EPI 2021 [4], y se expresa en mL/min/1,73 m^2. Un eGFR menor indica menor capacidad de filtrado.
- **Daño (albuminuria).** Se mide con la relación albúmina/creatinina en orina (ACR), en mg/g. Un ACR de 30 mg/g o más indica albuminuria aumentada, es decir, pérdida anormal de proteína por la orina.

El archivo asigna `ckd_stage` con la regla de la Tabla 2, según su diccionario de variables, `metadata.docx` [5].

`ckd_stage`	Regla del archivo
No CKD	eGFR ≥ 90 y ACR < 30
Stage 1	eGFR ≥ 90 y ACR ≥ 30
Stage 2	60 ≤ eGFR < 90
Stage 3a, 3b, 4 y 5	eGFR < 60 (cortes en 45, 30 y 15)
Unknown	eGFR ausente

Tabla 2: Regla con la que el archivo asigna `ckd_stage`. *Stage 2* se asigna solo por el filtrado, sin exigir un marcador de daño.

La guía clínica KDIGO [7] considera enfermedad renal crónica a un eGFR de 60 a 89 solo si además hay daño renal (por ejemplo, ACR ≥ 30). Por esa diferencia, los análisis de enfermedad renal de este trabajo usan un criterio clínico propio: CKD si el eGFR es menor a 60 o el ACR es de 30 o más (sección 2.10 de este informe). Dos limitaciones vienen del origen de los datos: hay una sola medición por persona, así que no se puede confirmar la persistencia de tres meses, y una asociación observada no demuestra causalidad.

1.3. Problemas identificados y su tratamiento

El análisis exploratorio del archivo crudo detectó 26 problemas, identificados como P1 a P26 y resumidos en la Tabla 3. Los más relevantes para el análisis renal son: la variable `ckd_present` cuenta como enfermas a las 5.607 personas sin eGFR [P1]; la regla de *Stage 2* marca como CKD al 46,8 % de los adultos con eGFR [P2]; los ceros de la edad y del índice de pobreza están guardados como un número minúsculo [P7] [P9]; las respuestas «no sabe» y «se negó» están guardadas como números [P12]; la edad, el ingreso y la albúmina en orina están censurados [P8] [P10] [P26]; y el archivo mezcla chicos y adultos [P22].

La limpieza (sección 2.10 de este informe) se aplica sobre una copia de trabajo, sin eliminar filas ni imputar faltantes: corrige los ceros y los códigos, construye las variables `smoking_status` y `ckd_clinical` (el criterio clínico) y define dos poblaciones de análisis. Las hipótesis sobre enfermedad renal se evalúan sobre los 5.575 adultos clasificados con el criterio clínico, de los cuales 972 (17,4 %) tienen CKD.

1.4. Organización del trabajo

La sección 2 presenta el análisis exploratorio del archivo crudo y la limpieza de los datos. La sección 3 plantea y valida seis hipótesis: tres propias (3.1 univariada, 3.2 bivariada y 3.3 multivariada) y las tres planteadas en el enunciado (3.4 a 3.6). La sección 4 resume los resultados, los hallazgos que atraviesan las hipótesis y las limitaciones del trabajo.

Todo el análisis se implementa en la notebook `TPE_CKD_NHANES_GRUP039.ipynb`. Las referencias del tipo «notebook, sección X» remiten a sus secciones: la sección 2 de la notebook (2.1 a 2.15) contiene el análisis exploratorio y la limpieza, y sus secciones 3.1 a 3.6 coinciden con las de este informe.

2. Análisis exploratorio de los datos

El análisis exploratorio se realizó sobre el archivo crudo, sin modificar ningún dato (notebook, secciones 2.1 a 2.14). Para cada variable se distinguieron tres capas: el tipo de dato que asigna pandas (`dtype`), lo que dice la metadata y su tipo estadístico real; cuando las tres no coinciden, eso es un hallazgo. Cada problema detectado se identifica con un código [P#].

2.1. Estructura y tipos de variables

El archivo tiene 11.933 filas y 29 columnas, que coinciden con los 11.933 participantes del ciclo: cada fila es una persona (notebook, sección 2.2). pandas asigna `float64` a 25 columnas, `int64` a `ckd_present` y texto a `gender`, `ethnicity` y `ckd_stage`. El `float64` no siempre se debe a los faltantes: `participant_id` está completa y sin decimales, y es `float64` porque el CSV escribe todos los números con «.0» [P13].

El tipo computacional no alcanza para clasificar las variables (notebook, sección 2.3). De las 25 columnas `float64`, 7 no son cantidades: el identificador y seis códigos de cuestionario. A la inversa, `ckd_stage`, que pandas lee como texto, es ordinal. Además, el código de `diabetes_diagnosed` (1 sí, 2 no, 3 borderline) no respeta el orden natural de la variable [P14]. Las variables categóricas se describen con frecuencias y proporciones, y las cuantitativas con la medida de centro y de dispersión que corresponde a su forma (sección 2.7 de este informe).

2.2. Valores faltantes y duplicados

Se distinguieron tres tipos de faltantes (notebook, sección 2.4):

- **Nulos explícitos.** Solo 6 columnas están completas. Los faltantes forman bloques con conteos casi iguales, uno por cada componente de la encuesta: sangre (alrededor de 5.600, el 47 %), orina (alrededor de 3.780), presión (4.416) y medidas corporales (entre 3.179 y 3.462). La creatinina, el eGFR y la categoría `Unknown` de `ckd_stage` coinciden en 5.607 casos.
- **Nulos disfrazados.** Los códigos 7 y 9 («se negó a responder» y «no sabe») aparecen en 36 respuestas (11 + 4 + 7 + 14) [P12]. El valor `5.397605e-79` aparece en 189 edades y en 100 índices de pobreza: es la forma en que quedaron los ceros al convertir los archivos originales de NHANES, y corresponde a bebés de menos de un año y a hogares de ingreso muy bajo [P7] [P9]. La categoría `Unknown` de `ckd_stage` representa la ausencia de eGFR [P6].
- **Faltantes por diseño.** NHANES no hace todas las preguntas ni todos los exámenes a todas las edades: la sangre, y por lo tanto el eGFR, se mide desde los 12 años, el tabaquismo se pregunta desde los 18 y el nivel educativo desde los 20 [P15]. Además, 3.089 filas no tienen

ningún dato de examen ni de laboratorio, aunque la metadata indica que cada fila corresponde a una persona examinada [P18].

No hay filas duplicadas ni identificadores repetidos (notebook, sección 2.5). Sin el identificador aparecen 364 filas iguales a otra, en 560 filas involucradas: son sobre todo chicos sin examen que coinciden en edad, sexo y grupo étnico, es decir, personas distintas, que se conservan [P24].

2.3. Variables demográficas y socioeconómicas

La edad va de 0 a 80 años, con media de 38,3 y mediana de 37 (notebook, sección 2.6.1). Un cuarto de la muestra tiene 13 años o menos. La barra de 80 de la Fig. 1 reúne a 525 personas de 80 años o más: es un valor censurado, no un pico real [P8]. La forma del histograma refleja el sobremuestreo por grupo de edad, no la pirámide de edades de EE.UU.

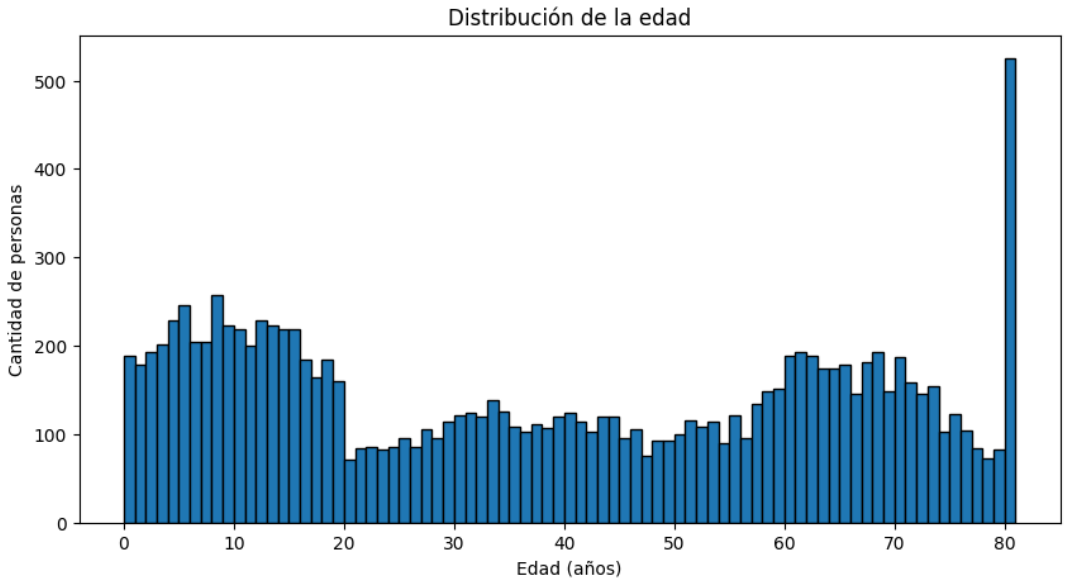


Fig. 1: Distribución de la edad, con un intervalo por año. La barra de 80 agrupa a todas las personas de 80 años o más (notebook, sección 2.6.1).

Hay 6.358 mujeres (53,3 %) y 5.575 hombres (46,7 %), y los blancos no hispanos son el 52,1 % de la muestra (notebook, sección 2.6.2). Como la mitad de la muestra pertenece a ese grupo, cualquier conteo absoluto de casos va a estar dominado por él solo por su tamaño, algo que se tiene en cuenta en la hipótesis (a). El nivel educativo solo se pregunta desde los 20 años: de sus 4.139 nulos, 4.124 son menores de 20, y entre las 7.783 personas con un código válido la moda es 5 (universitario o más) y la mediana 4 (notebook, sección 2.6.3).

El índice de pobreza, el ingreso familiar dividido por el umbral de pobreza del hogar, tiene una mediana de 2,50 y un primer cuartil de 1,18 (notebook, sección 2.6.4). La barra de 5 es la más alta

del histograma (Fig. 2): 2.149 personas, el 21,7 % de quienes tienen el dato, porque todos los ingresos de 5 veces el umbral o más quedan registrados como 5 [P10]. Los 2.041 nulos (17,1 %) no son faltantes por diseño ni completamente al azar: su porcentaje va de 14,2 % en los blancos no hispanos a 23,5 % en los asiáticos no hispanos, y casi no varía con la edad (entre 16,9 % y 17,3 %) [P11]. Por la censura, esta variable se resume con la mediana y los cuartiles.

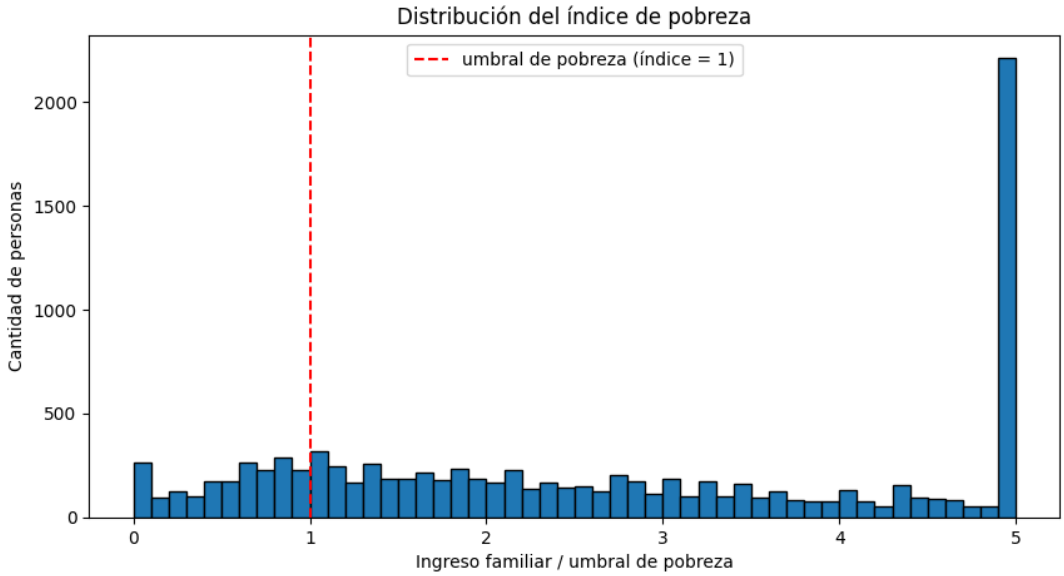


Fig. 2: Distribución del índice de pobreza. La línea roja marca el umbral de pobreza (índice = 1), y la barra de 5 agrupa a los ingresos de 5 veces el umbral o más (notebook, sección 2.6.4).

2.4. Medidas corporales, presión arterial y análisis de laboratorio

La altura y el peso mezclan dos poblaciones: al separar menores y adultos aparecen dos distribuciones distintas (Fig. 3), y el peso va de 2,7 kg a 248,2 kg [P22] (notebook, sección 2.7). El BMI se reconstruye exactamente desde el peso y la altura. La presión arterial es coherente: todos los valores son enteros, la sistólica nunca es menor que la diastólica y las dos faltan siempre juntas; las 66 sistólicas de 180 mmHg o más y las 10 diastólicas menores a 40 son clínicamente posibles. NHANES toma tres lecturas de presión por persona [8], y el archivo trae un solo valor sin indicar cuál [P20].

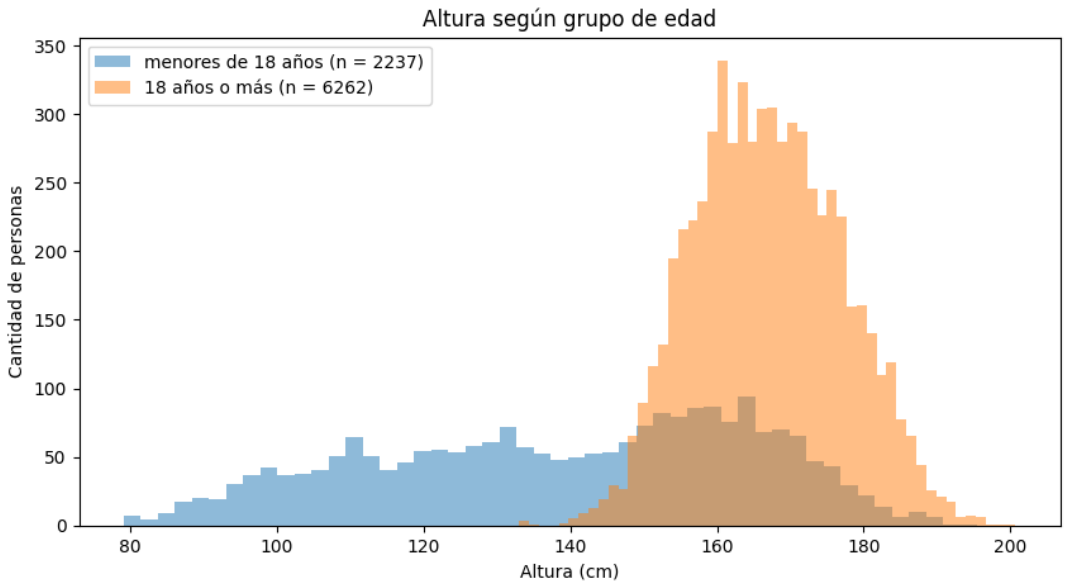


Fig. 3: Altura de los menores de 18 años y de los adultos. Las dos distribuciones casi no se superponen: una medida resumen de toda la muestra mezclaría dos poblaciones (notebook, sección 2.7).

En los análisis de sangre no hay valores fisiológicamente imposibles (notebook, sección 2.8). La creatinina es la variable más asimétrica del bloque (asimetría de 15,6): su mediana es 0,83 mg/dL y su máximo 15,17, por 11 personas con eGFR menor a 15. No son errores sino los casos más graves de lo que el trabajo estudia, por lo que se conservan y se resumen con medianas [P23].

El ACR es la variable más asimétrica del archivo (notebook, sección 2.9): mediana de 8,27 mg/g, media de 33,36 y máximo de 14.708, con un desvío siete veces mayor que la media. En escala logarítmica la distribución se vuelve casi simétrica y se ve dónde cae el umbral de 30 mg/g (Fig. 4); el logaritmo se usa solo para graficar. 1.009 personas (12,4 % de quienes tienen el dato) tienen un ACR de 30 o más. El valor 0,21 de la albúmina en orina aparece 488 veces: según la documentación de NHANES [9], son resultados por debajo del límite de detección reemplazados por un valor de relleno, es decir, un dato censurado por izquierda [P26]. No cambia la clasificación renal, porque las 488 personas tienen ACR menor a 30.

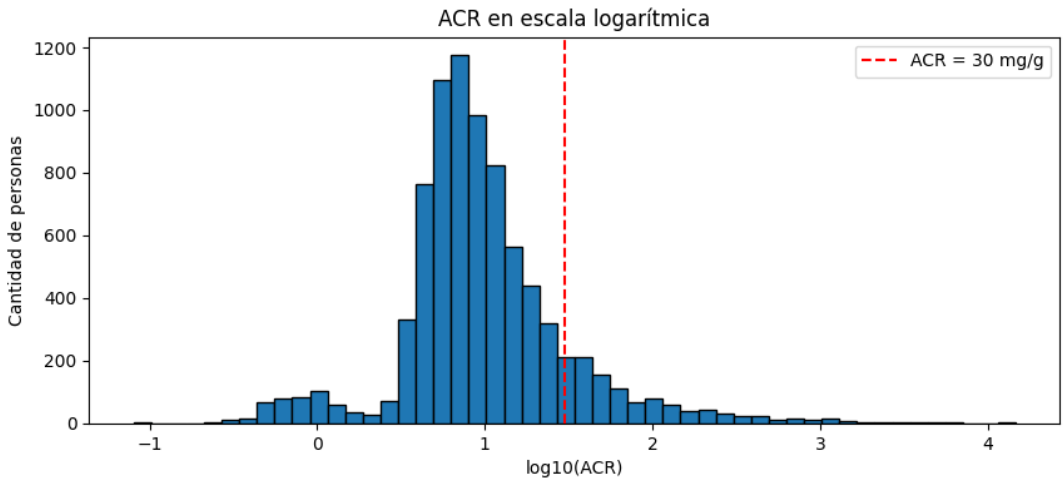


Fig. 4: ACR en escala logarítmica (base 10). La línea roja marca el umbral de albuminuria aumentada, 30 mg/g (notebook, sección 2.9).

2.5. Antecedentes de diabetes y tabaquismo

`diabetes_diagnosed` registra 1.081 personas con diabetes, 10.371 sin diabetes, 284 borderline, 4 con código 9 y 193 nulos, de los cuales 189 son bebés de menos de un año (notebook, sección 2.10). Las preguntas de seguimiento dependen de respuestas anteriores: el uso de insulina solo se pregunta a los 1.081 diabéticos, y el de pastillas, además, a 918 personas sin diabetes, un subconjunto definido por una variable que no está en el archivo [P16]. Una interpretación compatible con esos conteos es un diagnóstico previo de prediabetes, que explica también a las 60 personas que dicen no tener diabetes y toman pastillas para bajar la glucosa [P17]. En el tabaquismo, el 39,9 % de quienes respondieron fumó alguna vez (3.243 de 8.121); `current_smoker` solo existe para ellos, así que usada sola deja afuera a quienes nunca fumaron.

2.6. Variables derivadas y clasificación renal

Las tres variables derivadas se reproducen exactamente (notebook, sección 2.11.1): las diferencias máximas son de 0,05 en el BMI y de 0,005 en el ACR y en el eGFR, errores de redondeo que confirman que el eGFR se calculó con CKD-EPI 2021 sin ajuste por raza. Para las 298 personas de 80 años o más con eGFR, la ecuación usó 80 aunque su edad real sea mayor, lo que sobreestima su eGFR en alrededor de un 3 % a los 85 años [P5].

La regla de la Tabla 2 reproduce `ckd_stage` en todas las filas salvo en 70: personas con eGFR de 90 o más y sin ACR que el archivo clasificó como *No CKD*, tratando «sin dato de orina» como «orina normal» [P3] (notebook, sección 2.11.2). La categoría más grande es `Unknown`, con 5.607 personas (Fig. 5), y `ckd_present` vale 1 para el 69,9 % de la muestra porque codifica como enfermas a todas esas personas sin eGFR, entre ellas 2.545 menores de 12 años [P1] (notebook, sección 2.11.3).

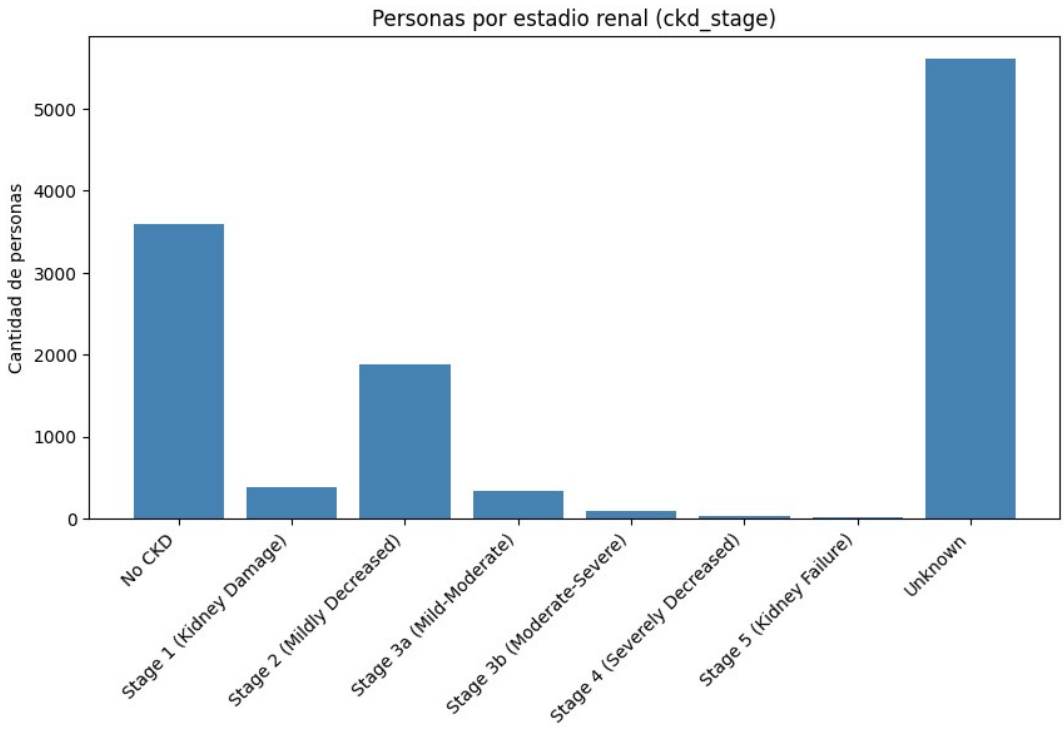


Fig. 5: Personas por estadio renal según `ckd_stage`. `Unknown` (5.607 personas) no es un estadio sino la ausencia de eGFR (notebook, sección 2.11.3).

De los 5.607 `Unknown`, 2.545 son menores de 12 años, 567 tienen entre 12 y 17 y 2.495 son adultos: 1.821 no concurrieron al examen y 674 lo hicieron pero no tienen creatinina en sangre (notebook, sección 2.11.4). Entre los adultos, la falta de eGFR varía según el grupo étnico: 28,8 % en los blancos no hispanos contra 37,2 % en los negros no hispanos [P6].

De las 1.875 personas en *Stage 2*, 1.645 tienen ACR menor a 30, es decir, un filtrado levemente disminuido sin marcador de daño [P2] (notebook, sección 2.11.5). Entre los 5.658 adultos con eGFR, la regla del archivo marca como CKD al 46,8 %, mientras que el criterio clínico marca al 17,4 % de los 5.575 clasificables. Como referencia, el CDC estima alrededor de un 14 % de CKD en los adultos de EE.UU. [10], una cifra no directamente comparable porque usa los pesos muestrales y excluye el *Stage 5*. Por último, 668 adolescentes de 12 a 17 años tienen un eGFR calculado con una ecuación desarrollada para adultos [P4] (notebook, sección 2.11.6), por lo que los análisis renales se restringen a adultos.

2.7. Forma, dispersión y valores atípicos

La medida de centro y de dispersión de cada variable cuantitativa se eligió según su forma (notebook, sección 2.12.1): media y desvío para las casi simétricas (eGFR, albúmina en sangre, bicarbonato y calcio, y con asimetría leve fósforo, ácido úrico y presión diastólica); mediana e IQR para las asimétricas a la derecha (ACR, albúmina y creatinina en orina, creatinina en sangre, urea,

BMI y presión sistólica), para las censuradas (edad, índice de pobreza y albúmina en orina) y para las que mezclan poblaciones (altura y peso). El ACR y la albúmina en orina tienen coeficientes de variación de 753 % y 494 %.

Los valores atípicos se evaluaron con tres criterios: el dominio (rangos fisiológicamente posibles), el de Tukey y el puntaje z (notebook, sección 2.12.2). Los dos criterios estadísticos no coinciden, y la diferencia se explica por la forma: en el ACR, Tukey marca 1.003 valores (12 %) y el puntaje z marca 46, porque el desvío está inflado por los extremos. Además, un valor es atípico respecto de una población: con los cuartiles de toda la muestra la altura tiene 770 atípicos (9,1 %), casi todos chicos, y con los de los adultos tiene 10. Ningún atípico encontrado es un error de carga, y los errores encontrados (ceros disfrazados y códigos 7/9) no son atípicos. Por eso no se eliminó ningún valor atípico.

2.8. Relaciones entre variables

Los pares con correlación fuerte ($|r| \geq 0{,}7$) son, al menos en parte, relaciones por construcción (notebook, sección 2.13.1): BMI y peso (Pearson 0,91), albúmina en orina y ACR (0,83), edad y eGFR (−0,78, porque la ecuación incluye la edad) y creatinina en sangre y eGFR (Spearman −0,71). Con variables tan asimétricas, el coeficiente de Pearson no se interpreta sin el gráfico y sin el de Spearman: entre la creatinina en sangre y el ACR, Pearson da 0,50 y Spearman −0,11, porque unas pocas personas con falla renal tienen las dos variables altísimas a la vez (Fig. 6) [P23].

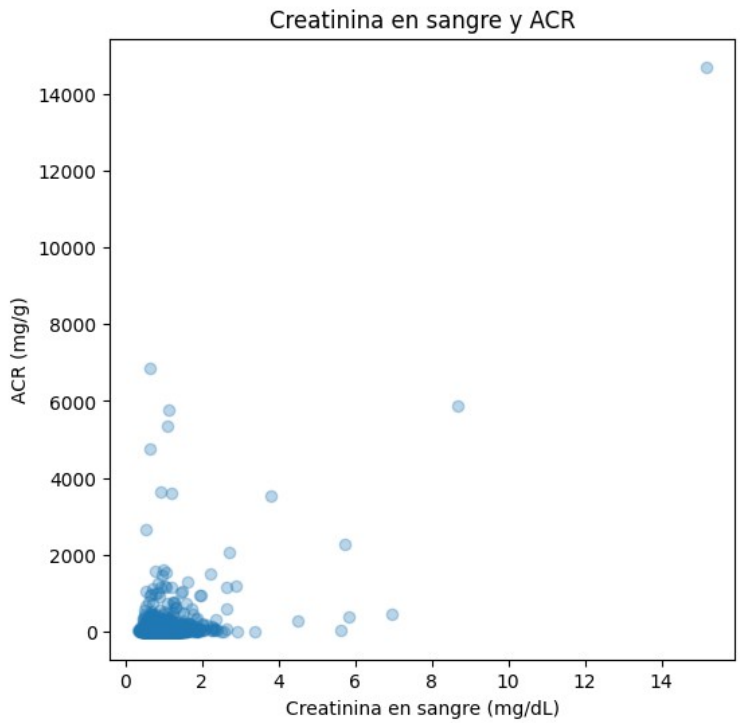


Fig. 6: Creatinina en sangre y ACR. Unos pocos puntos con valores extremos en las dos variables producen un Pearson de 0,50, mientras que el Spearman es −0,11 (notebook, sección 2.13.1).

Entre los 5.658 adultos con eGFR, los 477 con eGFR menor a 60 tienen una presión sistólica más alta: mediana de 126 contra 119 mmHg (Fig. 7; notebook, sección 2.13.2). Pero la edad está detrás de las dos variables: de los 18–39 años a los 60 o más, la mediana de la sistólica sube de 112 a 127 mmHg y el porcentaje con eGFR menor a 60 sube de 0,1 % a 16,9 %. La edad es un confusor que se tiene en cuenta en las hipótesis (b) y (c).

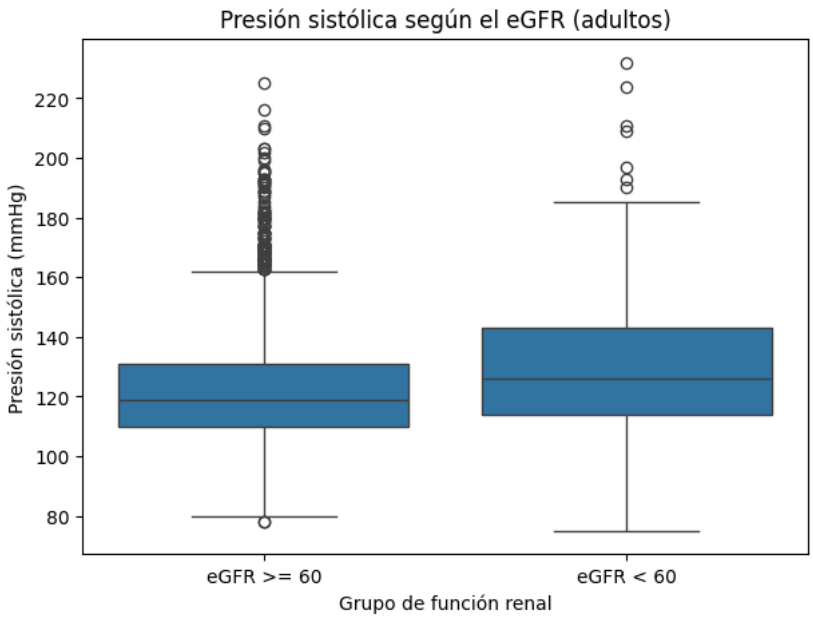


Fig. 7: Presión sistólica de los adultos según el eGFR sea menor a 60 o no. El grupo con eGFR bajo tiene la presión más alta, pero también es mayor (notebook, sección 2.13.2).

Los blancos no hispanos son el 66,0 % de los adultos con eGFR menor a 60 (315 de 477), pero dentro de su grupo la proporción es 9,4 %, menor que la de los negros no hispanos, 12,5 % (Fig. 8; notebook, sección 2.13.3). También son el grupo con la edad mediana más alta: 60 años, contra 44 en los mexicano-americanos. Conteo y proporción responden preguntas distintas, lo que motiva las dos lecturas de la hipótesis (a).

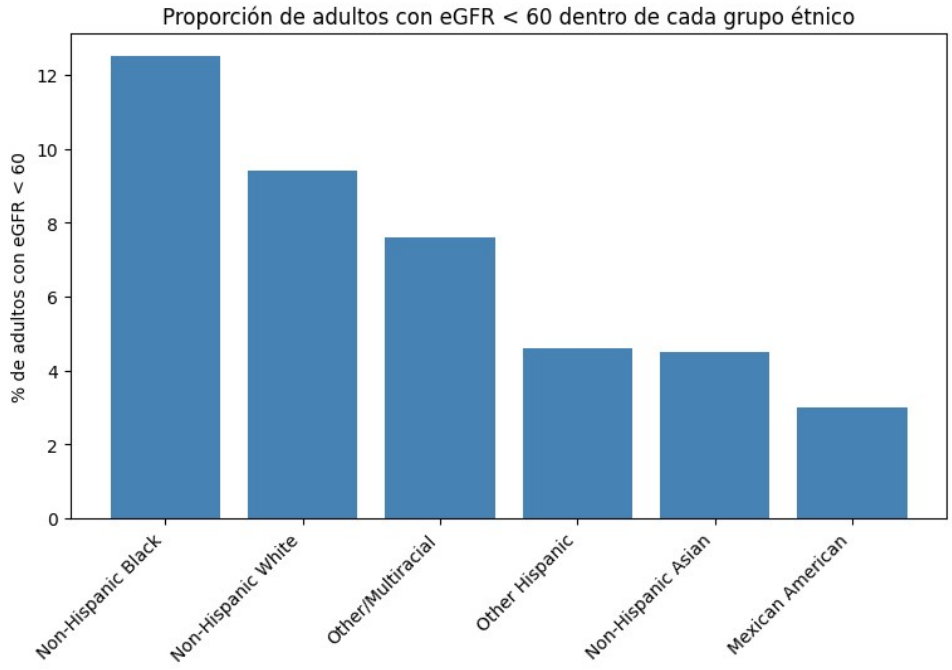


Fig. 8: Proporción de adultos con eGFR menor a 60 dentro de cada grupo étnico (notebook, sección 2.13.3).

2.9. Resumen de los problemas detectados

La Tabla 3 resume los 26 problemas detectados en el archivo crudo, con su evidencia y la sección de la notebook en la que se analiza cada uno (notebook, sección 2.14). Su tratamiento se describe en la sección siguiente.

ID	Problema	Evidencia	Sección
P1	`ckd_present` codifica como 1 a los `Unknown` (sin eGFR), igual que a los enfermos	8.341 valores 1 (69,9 %), de los cuales 5.607 son `Unknown`	2.11.3
P2	`ckd_stage`: *Stage 2* no exige un marcador de daño	1.645 de 1.875 en *Stage 2* con ACR < 30; adultos: 46,8 % contra 17,4 %	2.11.5
P3	`ckd_stage`: personas sin ACR clasificadas como *No CKD*	70 con eGFR ≥ 90 y sin ACR	2.11.2
P4	`egfr`: ecuación de adultos aplicada a adolescentes	668 de 12 a 17 años; 85 en *Stage 1*	2.11.6
P5	`egfr`: calculado con la edad censurada en 80	298 personas; sobreestimación de ~3 % a los 85 años	2.11.1
P6	`ckd_stage`: `Unknown` es un faltante disfrazado que no falta al azar	5.607: 2.545 menores de 12, 567 de 12 a 17 y 2.495 adultos; varía por grupo étnico	2.11.4
P7	`age`: el cero aparece como `5.397605e-79`	189 valores (bebés de menos de un año)	2.4.2
P8	`age`: censura en 80	525 personas	2.6.1
P9	`poverty_income_ratio`: el cero aparece como `5.397605e-79`	100 valores	2.4.2
P10	`poverty_income_ratio`: censura en 5	2.149 personas (21,7 % de quienes tienen dato)	2.6.4
P11	`poverty_income_ratio`: ingreso no informado, no al azar	2.041 nulos (17,1 %); de 14,2 % a 23,5 % según el grupo étnico	2.6.4
P12	Códigos 7/9 guardados como números (educación, diabetes, pastillas y tabaquismo)	11 + 4 + 7 + 14 casos	2.4.2
P13	Identificador y categóricas guardados como `float64`; `ckd_stage` es texto pero ordinal	7 de las 25 columnas `float64` no son cantidades	2.2, 2.3
P14	`diabetes_diagnosed`: el código no respeta el orden natural	1 sí, 2 no, 3 borderline	2.10
P15	Faltantes por diseño (cuestionario, laboratorio, presión y altura)	`insulin_use`: 10.852 nulos; `current_smoker`: 8.690; educación: 4.124 menores de 20	2.4.3, 2.10
P16	`diabetes_pills` preguntada a un subconjunto definido por una variable ausente	918 personas sin diabetes tienen la pregunta	2.10
P17	Respuestas de diabetes aparentemente incoherentes	60 dicen no tener diabetes y toman pastillas	2.10
P18	La metadata dice que cada fila es una persona examinada	3.089 filas sin ningún dato de examen ni de laboratorio	2.4.3
P19	`height_cm`: «altura o longitud», pero no hay datos de menores de 2 años	0 de 368 menores de 2 años	2.4.3
P20	Presión: un solo valor de las tres lecturas, sin aclarar cuál	—	2.7
P21	Creatinina en orina sin albúmina, y por lo tanto sin ACR	1 persona	2.9
P22	Mezcla de chicos y adultos	altura: 770 atípicos de Tukey en toda la muestra contra 10 entre adultos	2.7, 2.12
P23	Valores extremos clínicamente reales que dominan la media, el desvío y Pearson	creatinina hasta 15,17; ACR hasta 14.708 (CV de 753 %)	2.8, 2.9, 2.12, 2.13.1
P24	Filas iguales salvo el identificador (personas distintas)	196 combinaciones en 560 filas: 364 copias	2.5

ID	Problema	Evidencia	Sección
P25	Sin pesos muestrales: se describe la muestra, no la población	—	1.1, 2.6.2, 2.13.3
P26	`urine_albumin`: valores bajo el límite de detección reemplazados por 0,21	488 valores; la documentación de NHANES informa 488	2.9

Tabla 3: Problemas detectados en el archivo crudo, con su evidencia y la sección de la notebook en la que se analizan (notebook, sección 2.14).

2.10. Limpieza de los datos

La limpieza se aplica sobre una copia del dataset crudo; el archivo CSV no se modifica (notebook, sección 2.15). Los criterios generales son tres. **No se elimina ninguna fila**: las restricciones de cada análisis se aplican como selecciones. **No se imputan faltantes**: los faltantes por diseño no tienen un valor real que falte, el ingreso no informado no falta al azar y el estado renal es la variable que se estudia. **No se eliminan valores atípicos**: no se encontraron valores imposibles, y los extremos de las variables renales son los casos que el trabajo estudia. Cada acción se verifica con conteos antes y después:

- **Ceros disfrazados [P7] [P9]** (notebook, sección 2.15.2). El valor minúsculo se reemplaza por 0, que es el valor real, y no por un faltante: 189 edades y 100 índices de pobreza. En el índice, dejarlo como faltante excluiría de los análisis socioeconómicos a los hogares de menores ingresos (76 adultos).
- **Variables de cuestionario [P12] [P13] [P14]** (notebook, sección 2.15.3). Se recodifican con un diccionario de códigos válidos, por lo que los 36 códigos 7/9 pasan a faltante. `diabetes_diagnosed` se renombra como `diabetes_status`, con un código que respeta el orden (0 no, 1 borderline, 2 sí: 10.371, 284 y 1.081 personas), y las binarias quedan en 0/1.
- **Tabaquismo [P15]** (notebook, sección 2.15.4). `ever_smoked` y `current_smoker` se combinan en `smoking_status`: 0 nunca fumó (4.878), 1 ex fumador (2.053) y 2 fumador actual (1.190).
- **Función renal [P1] [P2] [P3] [P4] [P6]** (notebook, sección 2.15.5). `Unknown` pasa a faltante, `ckd_present` se elimina de la copia de trabajo y se construye `ckd_clinical` con el criterio clínico de la Tabla 4.
- **Problemas que se conservan** (notebook, sección 2.15.6). Las censuras [P5] [P8] [P10] [P26]; las 60 personas sin diabetes diagnosticada que toman pastillas [P16] [P17], que se mantienen sin diabetes porque la medicación sola no prueba ese diagnóstico; y las filas iguales salvo el identificador [P24].

Situación	ckd_clinical	Motivo
menor de 18 años	faltante	el eGFR se calcula con una ecuación para adultos [P4]
adulto sin eGFR	faltante	sin el filtrado no se puede confirmar ni descartar la enfermedad
adulto con eGFR < 60	1	cumple el criterio por el filtrado, tenga o no ACR
adulto con eGFR ≥ 60 y ACR ≥ 30	1	cumple el criterio por el daño
adulto con eGFR ≥ 60 y ACR < 30	0	no cumple ninguno de los dos ejes
adulto con eGFR ≥ 60 y sin ACR	faltante	no se puede suponer que el ACR es normal [P3]

Tabla 4: Criterio clínico de enfermedad renal crónica (`ckd_clinical`): CKD si eGFR < 60 o ACR ≥ 30, solo en adultos y exigiendo el eGFR (notebook, sección 2.15.5).

El criterio clasifica a 5.575 adultos: 972 con CKD (17,4 %) y 4.603 sin CKD. Quedan sin clasificar 3.780 menores de 18 años, 83 adultos con eGFR ≥ 60 y sin ACR y 2.495 adultos sin eGFR, el 30,6 % de los 8.153 adultos (notebook, sección 2.15.5). Estos últimos no se imputan, porque estimar el eGFR equivaldría a asignar diagnósticos. Su exclusión no sesga los resultados solo si la falta de eGFR no depende del estado renal, algo que no se puede comprobar con los datos. Como indicio a favor, los adultos con y sin eGFR tienen una edad media (52,7 y 51,0 años) y una proporción de diabetes diagnosticada (13,5 % y 12,4 %) similares; en contra, la falta de eGFR varía según el grupo étnico.

Se definen dos poblaciones de análisis (notebook, sección 2.15.7): `poblacion_adultos`, las 8.153 personas de 18 años o más, y `poblacion_ckd`, los 5.575 adultos clasificados, que usan todas las hipótesis de enfermedad renal. La copia de trabajo conserva las 11.933 filas y tiene 30 columnas: las 29 del archivo, menos `ckd_present`, más `smoking_status` y `ckd_clinical` (notebook, sección 2.15.8).

3. Hipótesis y resolución

Las seis hipótesis comparten los siguientes criterios (notebook, sección 3):

- **Nivel de significancia:** $\alpha = 0{,}05$.
- **Población:** las hipótesis sobre enfermedad renal usan `poblacion_ckd`, los 5.575 adultos clasificados, y la variable `ckd_clinical`. Cuando una hipótesis necesita otra variable, se informa cuántas personas quedan con ese dato.
- **CKF y CKD:** las hipótesis (a) y (b) del enunciado mencionan CKF y la (c), CKD. Se interpretan como el mismo concepto, enfermedad renal crónica; la lectura alternativa, CKF como falla renal (*Stage 5*), dejaría solo 11 casos, demasiado pocos para cualquier análisis.
- **Comparación de una variable cuantitativa entre dos grupos** (hipótesis 2 y 5): boxplot; normalidad de cada grupo con Shapiro-Wilk y QQ plot; igualdad de varianzas con Levene; test t para muestras independientes, con la corrección de Welch si Levene rechaza; y un test no paramétrico de control (Mann-Whitney U si las varianzas pueden considerarse iguales, Kruskal-Wallis si no). Con grupos de cientos o miles de personas el test t es robusto a la falta de normalidad, por lo que la normalidad se informa pero no decide sola el test.
- **Modelos de regresión** (hipótesis 3 y 6): se usan los casos completos; las variables cualitativas se codifican como columnas 0/1; los predictores cuantitativos se estandarizan (media 0 y desvío 1) para que sus coeficientes sean comparables, y se informan también en unidades originales; las columnas 0/1 no se estandarizan, porque su coeficiente ya expresa la diferencia con la categoría de referencia. Cada coeficiente se informa con su intervalo de confianza del 95 %, y la multicolinealidad se evalúa con las correlaciones entre los predictores y con el factor de inflación de la varianza (VIF), calculado con la constante del modelo.

3.1. Hipótesis 1 (propia, univariada): prevalencia de enfermedad renal crónica

3.1.1. Definición de la hipótesis

Motivación. El CDC estima que alrededor del 14 % de los adultos de EE.UU. tiene enfermedad renal crónica [10]. Antes de estudiar con qué factores se asocia la enfermedad, interesa saber si la proporción de adultos con CKD de la muestra, definida con el criterio clínico, es compatible con esa estimación.

Hipótesis. La proporción de adultos con enfermedad renal crónica en la muestra difiere del 14 % estimado por el CDC para los adultos de EE.UU.

Utilidad. Cuantifica la frecuencia de la enfermedad en la población que usan los análisis siguientes, contrasta el criterio clínico con una estimación externa e indica si las proporciones de la muestra pueden leerse como proporciones de la población.

3.1.2. Estrategia de abordaje

Se analiza `ckd_clinical` (binaria) en los 5.575 adultos de `poblacion_ckd`. Sea p la proporción de adultos con CKD:

- H_0: p = 0,14
- H_1: p ≠ 0,14 (bilateral: la hipótesis no fija una dirección)

Se usa el **test Z para una proporción**, $z = (\hat{p} - p_0) / \sqrt{(p_0 \cdot (1 - p_0) / n)}$. En una variable binaria la varianza bajo H_0 queda determinada por p_0 = 0,14, por lo que no se estima con la muestra y el estadístico se compara con la distribución normal estándar. Supuestos: observaciones independientes, y $n \cdot p_0$ y $n \cdot (1 - p_0)$ de al menos 10. Para describir la magnitud de la diferencia se calcula además el intervalo de confianza del 95 % de la proporción.

3.1.3. Resultados obtenidos y discusión

En la muestra hay 972 adultos con CKD sobre 5.575 clasificados: 17,4 %, con un intervalo de confianza del 95 % de 16,4 % a 18,4 % (Fig. 9). Los supuestos se cumplen ($n \cdot p_0$ = 780,5 y $n \cdot (1 - p_0)$ = 4.794,5). El estadístico es z = 7,39, con un p-valor menor a 0,001.

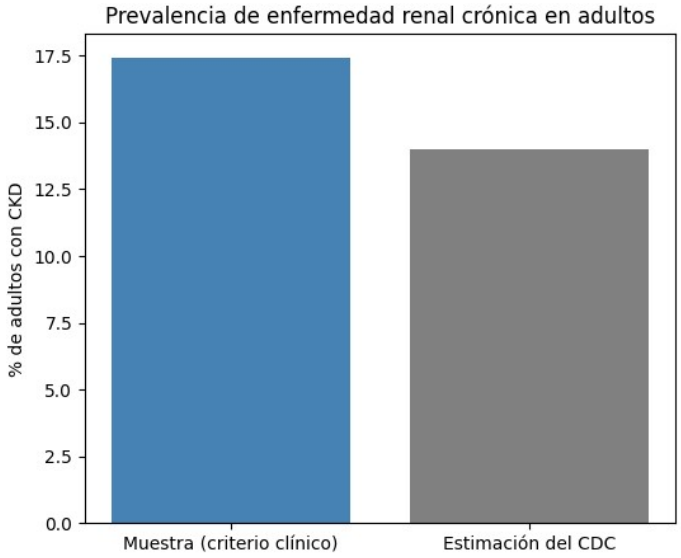


Fig. 9: Proporción de adultos con enfermedad renal crónica en la muestra (criterio clínico) y estimación del CDC (notebook, sección 3.1.3).

Conclusión: se rechaza H_0. La proporción de adultos con enfermedad renal crónica en la muestra (17,4 %) difiere significativamente del 14 % estimado por el CDC y es mayor: el

intervalo de confianza del 95 % queda completo por encima de ese valor. La hipótesis se confirma.

Discusión. La diferencia es de unos 3,4 puntos porcentuales, entre 2,4 y 4,4 según el intervalo. No implica que la prevalencia real de EE.UU. sea otra: el archivo no tiene pesos muestrales [P25], el ciclo sobremuestrea por grupo de edad y la enfermedad renal es mucho más frecuente en edades avanzadas (el eGFR menor a 60 pasa de 0,1 % entre los 18 y 39 años a 16,9 % a partir de los 60). Además, la estimación del CDC usa los pesos muestrales y excluye el *Stage 5*, por lo que las dos cifras no se calculan igual. Como limitaciones, quedan fuera los 2.495 adultos sin eGFR, el diseño muestral complejo hace que las observaciones no sean completamente independientes y una sola medición no confirma la persistencia de tres meses. En consecuencia, las hipótesis siguientes comparan grupos dentro de la muestra, y la edad se considera como posible confusor.

Ubicación en el código: *notebook, sección 3.1 (cálculos en 3.1.3).*

3.2. Hipótesis 2 (propia, bivariada): ácido úrico y enfermedad renal crónica

3.2.1. Definición de la hipótesis

Motivación. La metadata describe al ácido úrico como un producto del metabolismo de las purinas que se elimina en parte por los riñones [5]. Si el filtrado renal disminuye, es esperable que el ácido úrico se acumule en la sangre.

Hipótesis. El nivel de ácido úrico en sangre difiere entre los adultos con y sin enfermedad renal crónica.

Utilidad. Complementa a las hipótesis del enunciado, centradas en factores de riesgo, con una variable metabólica vinculada a la función renal. El ácido úrico no interviene en la definición de CKD (el criterio usa el eGFR y el ACR), por lo que una asociación no está dada por construcción.

3.2.2. Estrategia de abordaje

Se comparan dos grupos independientes de `poblacion_ckd`, los adultos con y sin CKD, en `uric_acid` (cuantitativa continua, mg/dL). Sean μ_1 y μ_0 las medias de ácido úrico de los adultos con y sin CKD:

- H_0: $\mu_1 = \mu_0$
- H_1: $\mu_1 \neq \mu_0$ (bilateral)

Se aplica el procedimiento de comparación de dos grupos descrito al inicio de la sección 3. El sexo y la edad se consideran como posibles confusores.

3.2.3. Resultados obtenidos y discusión

Los 972 adultos con CKD tienen una media de ácido úrico de 5,65 mg/dL y una mediana de 5,50; los 4.603 sin CKD, una media de 5,05 y una mediana de 5,00 (Fig. 10). Shapiro-Wilk rechaza la normalidad en los dos grupos (estadístico de 0,984 en ambos, $p < 0,001$), con un apartamiento concentrado en la cola derecha; con estos tamaños de grupo el test t es robusto a esa falta de normalidad. Levene rechaza la igualdad de varianzas (estadístico de 42,55, $p < 0,001$; desvíos de 1,62 y 1,35 mg/dL), por lo que se usa el test t de Welch: $t = 10,81$, $p < 0,001$, con una diferencia de medias de 0,60 mg/dL. El control de Kruskal-Wallis coincide (estadístico de 116,35, $p < 0,001$).

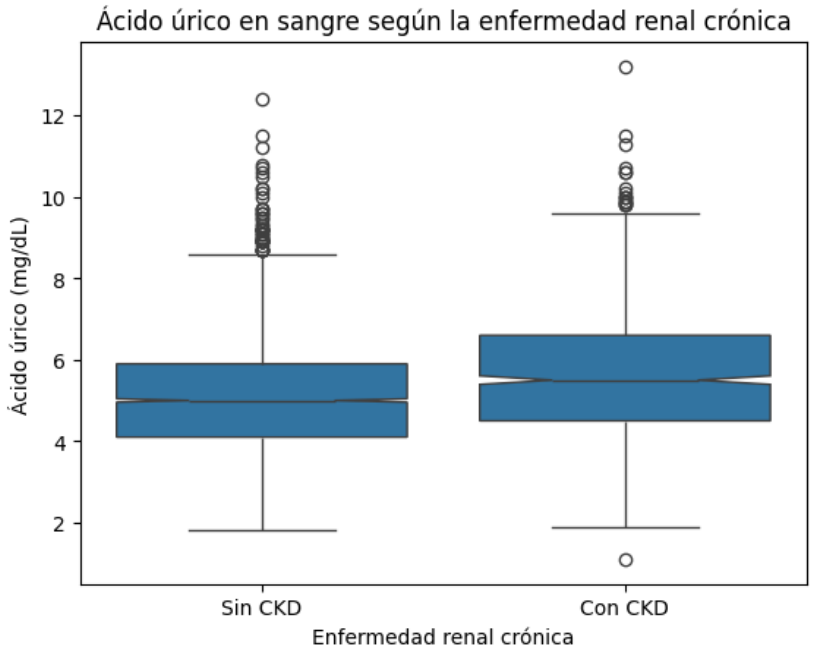


Fig. 10: Ácido úrico en sangre de los adultos sin y con enfermedad renal crónica (criterio clínico); las muescas marcan el intervalo de confianza de la mediana (notebook, sección 3.2.3).

Conclusión: se rechaza H_0. El nivel de ácido úrico en sangre difiere significativamente entre los adultos con y sin enfermedad renal crónica, y es mayor en los adultos con CKD (media de 5,65 contra 5,05 mg/dL). La hipótesis se confirma.

Discusión. La diferencia, de 0,6 mg/dL en la media y de 0,5 en la mediana, es moderada frente a la variabilidad dentro de cada grupo (desvíos de 1,35 y 1,62 mg/dL). Es coherente con que el ácido úrico se elimine en parte por los riñones [5], pero con una sola medición por persona no se puede establecer qué ocurrió primero: se trata de una asociación y no de una relación causal. Los hombres tienen más ácido úrico que las mujeres (mediana de 5,7 contra 4,5 mg/dL) y algo más de CKD (18,5 % contra 16,6 %), aunque la diferencia se mantiene dentro de cada sexo: 5,1 contra 4,4 mg/dL en las mujeres y 6,0 contra 5,7 en los hombres. Los adultos con CKD son

además mayores (mediana de 68 contra 52 años). El análisis conjunto con la edad, el sexo y el BMI corresponde a la hipótesis 3.

Ubicación en el código: *notebook, sección 3.2 (cálculos en 3.2.3).*

3.3. Hipótesis 3 (propia, multivariada): ácido úrico ajustado por edad, sexo y BMI

3.3.1. Definición de la hipótesis

Motivación. En la hipótesis 2, los adultos con CKD tienen en promedio 0,60 mg/dL más de ácido úrico. Esa comparación no considera otras diferencias entre los grupos que también pueden vincularse con el ácido úrico: los hombres tienen más ácido úrico que las mujeres y una proporción algo mayor de CKD, y los adultos con CKD son mayores. El BMI se incluye porque la metadata menciona el exceso de peso entre los factores relacionados con el deterioro renal [5]: si además se vinculara con el ácido úrico, podría explicar parte de la diferencia.

Hipótesis. La diferencia de ácido úrico entre los adultos con y sin enfermedad renal crónica se mantiene al comparar adultos de igual edad, sexo y BMI.

Utilidad. Distingue si el vínculo de la hipótesis 2 es propio de la enfermedad renal o refleja diferencias de edad, sexo o peso entre los grupos, cuantifica la diferencia que queda al tener en cuenta esas variables y muestra en qué grupos aparece.

3.3.2. Estrategia de abordaje

Se ajusta una **regresión lineal múltiple** por mínimos cuadrados sobre los adultos de `poblacion_ckd` con datos de ácido úrico, edad, sexo y BMI (casos completos), con las variables de la Tabla 5:

Variable	Rol	Tipo	Codificación en el modelo
`uric_acid`	respuesta	cuantitativa continua (mg/dL)	sin transformar
`ckd_clinical`	predictor	binaria	0/1 (1 = con CKD)
`age`	predictor	cuantitativa continua (años)	estandarizada
`gender`	predictor	binaria	`hombre`: 1 hombre, 0 mujer
`bmi`	predictor	cuantitativa continua (kg/m^2)	estandarizada

Tabla 5: Variables del modelo lineal de la hipótesis 3, con su tipo y su codificación (notebook, sección 3.3.2).

El modelo es uric_acid = $\beta_0 + \beta_1 \cdot$ ckd_clinical $+ \beta_2 \cdot$ age $+ \beta_3 \cdot$ hombre $+ \beta_4 \cdot$ bmi $+ \varepsilon$. Como `ckd_clinical` es una variable 0/1, β_1 es directamente la diferencia de ácido úrico, en mg/dL, entre adultos con y sin CKD de igual edad, sexo y BMI:

- H_0: $\beta_1 = 0$ (a igualdad de edad, sexo y BMI, el ácido úrico no difiere según la CKD)

- H_1: $\beta_1 \neq 0$ (bilateral)

Se usa el test t del coeficiente, y se informan además el test F (significancia global) y el R^2. Los supuestos se evalúan sobre los residuos: normalidad (QQ plot y tests de Omnibus y Jarque-Bera), homocedasticidad (valores ajustados contra residuos), independencia (Durbin-Watson), linealidad (residuos contra cada predictor cuantitativo) y ausencia de multicolinealidad (correlaciones y VIF). Como control que no depende de la normalidad, se compara el ácido úrico de los adultos con y sin CKD con el test de Kruskal-Wallis dentro de cada combinación de sexo y grupo de edad (18 a 39, 40 a 59 y 60 años o más).

3.3.3. Resultados obtenidos y discusión

El modelo usa 5.514 adultos, 949 con CKD; 61 de los 5.575 clasificados no tienen BMI. El ácido úrico se correlaciona más con el sexo (0,41) y el BMI (0,27) que con la CKD (0,16), y entre los predictores la correlación más alta es la de la CKD con la edad (0,30) (Fig. 11). El modelo es significativo (F = 528,6, p < 0,001) y explica el 27,7 % de la variabilidad del ácido úrico (R^2 = 0,277). La Tabla 6 presenta los coeficientes.

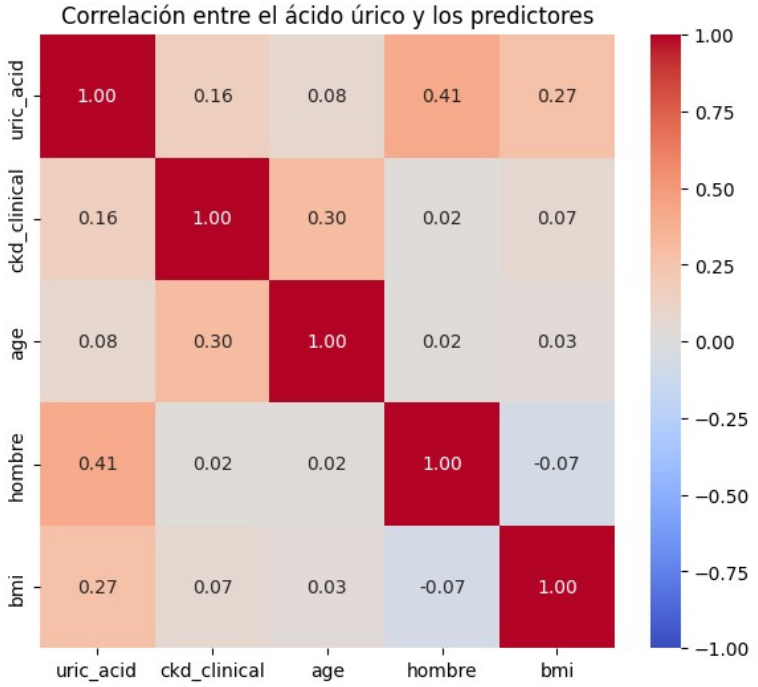


Fig. 11: Correlación entre el ácido úrico y los predictores del modelo lineal (notebook, sección 3.3.3).

Variable	Coeficiente	IC 95 %	En unidades originales	p-valor
CKD	0,46	0,38 a 0,55	0,46 mg/dL más con CKD	< 0,001
Hombre	1,21	1,15 a 1,28	1,21 mg/dL más que las mujeres	< 0,001
BMI (estandarizado)	0,411	0,379 a 0,442	0,057 mg/dL por kg/m^2 (desvío de 7,24 kg/m^2)	< 0,001
Edad (estandarizada)	0,029	−0,004 a 0,062	0,002 mg/dL por año (desvío de 17,97 años)	0,083
Constante	4,53	4,48 a 4,57	mujeres sin CKD con edad y BMI promedio	< 0,001

Tabla 6: Coeficientes del modelo lineal del ácido úrico, con su intervalo de confianza del 95 % y su lectura en unidades originales (notebook, sección 3.3.3).

La diferencia por la CKD pasa de 0,60 mg/dL sin ajustar a **0,46 mg/dL** ajustada por edad, sexo y BMI (IC 95 %: 0,38 a 0,55; t = 10,32, p < 0,001). En cuanto a los supuestos, Omnibus y Jarque-Bera rechazan la normalidad de los residuos (p < 0,001), aunque el QQ plot sigue la recta salvo en la cola derecha (Fig. 12; asimetría de 0,55 y curtosis de 4,6). Los residuos forman una banda alrededor de 0, sin forma de embudo, pero su desvío es mayor en el grupo con CKD (1,53 contra 1,12 mg/dL), la misma diferencia de dispersión que detectó Levene en la hipótesis 2. El Durbin-Watson es 1,96. Contra la edad no hay patrones curvos; contra el BMI tampoco, salvo por encima de 50 kg/m^2, donde hay pocos adultos y los residuos tienden a ser negativos. Los VIF de los predictores van de 1,005 a 1,103.

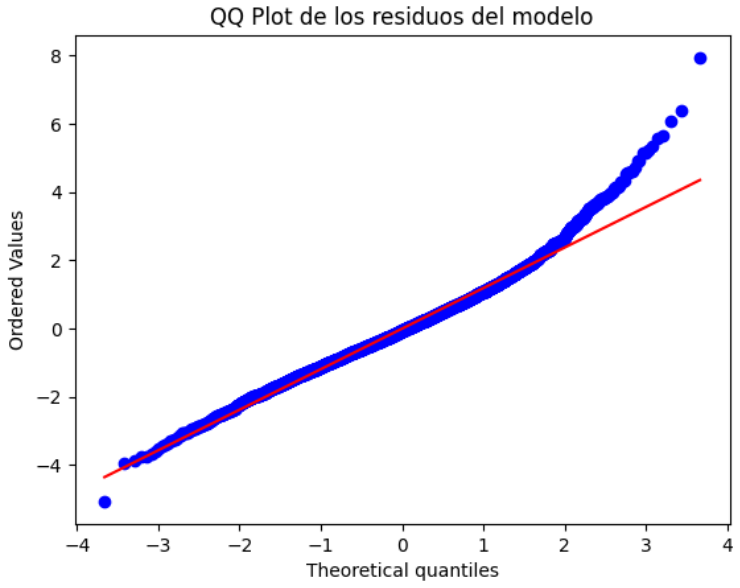


Fig. 12: QQ plot de los residuos del modelo lineal: el apartamiento de la recta se limita a la cola derecha (notebook, sección 3.3.3).

El control de Kruskal-Wallis (Tabla 7) muestra diferencias significativas en las mujeres de 40 a 59 años y en los adultos de 60 años o más de ambos sexos, y no en los grupos de 18 a 39 años ni

en los hombres de 40 a 59. Entre los casos, tienen eGFR menor a 60 el 1,1 % de los de 18 a 39 años (87 casos), el 29,4 % de los de 40 a 59 (180) y el 59,7 % de los de 60 o más (682).

Grupo	Mediana con CKD (mg/dL)	Mediana sin CKD (mg/dL)	p-valor
Mujeres de 18 a 39 años	4,30 (n = 55)	4,20 (n = 808)	0,630
Mujeres de 40 a 59 años	5,00 (n = 113)	4,30 (n = 746)	< 0,001
Mujeres de 60 años o más	5,40 (n = 328)	4,50 (n = 964)	< 0,001
Hombres de 18 a 39 años	5,85 (n = 32)	5,80 (n = 654)	0,664
Hombres de 40 a 59 años	5,40 (n = 67)	5,70 (n = 617)	0,277
Hombres de 60 años o más	6,00 (n = 354)	5,50 (n = 776)	< 0,001

Tabla 7: Control de Kruskal-Wallis: ácido úrico de los adultos con y sin CKD dentro de cada sexo y grupo de edad (notebook, sección 3.3.3).

Conclusión: se rechaza H_0. A igualdad de edad, sexo y BMI, los adultos con enfermedad renal crónica tienen en promedio 0,46 mg/dL más de ácido úrico (IC 95 %: 0,38 a 0,55), frente a 0,60 mg/dL sin ajustar. La diferencia se mantiene, por lo que la hipótesis se confirma. Los supuestos de normalidad y homocedasticidad se cumplen solo en parte, y el control no paramétrico muestra que la diferencia se concentra en los adultos de 60 años o más y en las mujeres de 40 a 59.

Discusión. La diferencia baja de 0,60 a 0,46 mg/dL: una parte de lo observado en la hipótesis 2 se debía a las otras variables. El sexo y el BMI tienen coeficientes grandes y significativos, mientras que la edad, a igualdad de las demás, no se vincula significativamente con el ácido úrico. Aun así, la CKD conserva un vínculo significativo y la mayor parte de la diferencia. En los adultos de 18 a 39 años no hay diferencia, y en ese grupo casi ningún caso tiene el filtrado disminuido (1,1 %): los casos jóvenes se definen sobre todo por la albuminuria. En los adultos de 60 años o más, donde la mayoría de los casos (59,7 %) tiene eGFR menor a 60, la diferencia es clara. Una interpretación coherente con ese patrón es que el ácido úrico se acumule cuando disminuye el filtrado más que cuando solo hay pérdida de albúmina; el modelo, sin embargo, no separa los dos ejes de la enfermedad, y los grupos jóvenes tienen pocos casos (55 y 32), así que la falta de significancia no prueba que no haya diferencia.

El control no paramétrico no depende de la normalidad y coincide con el modelo en los grupos con más casos, por lo que la conclusión no descansa solo en ese supuesto. La mayor dispersión de los residuos en el grupo con CKD hace que el error estándar del coeficiente sea aproximado, y el intervalo de confianza se interpreta como una referencia. El R^2 de 0,277 indica que la mayor parte de la variabilidad del ácido úrico depende de factores que el archivo no registra. Con una sola medición por persona, el resultado es una asociación.

Ubicación en el código: *notebook, sección 3.3 (cálculos en 3.3.3).*

3.4. Hipótesis 4 (a): «La mayoría de los casos de CKF identificados corresponde a blancos no-hispánicos»

3.4.1. Definición de la hipótesis

Motivación. En el análisis exploratorio, los blancos no hispanos son el 52,1 % de la muestra y el grupo con la edad mediana más alta (secciones 2.3 y 2.8 de este informe). Como la enfermedad renal es más frecuente a mayor edad, es esperable que concentren buena parte de los casos.

Hipótesis. La mayoría de los casos de enfermedad renal crónica identificados corresponde a blancos no hispanos (CKF se interpreta como CKD).

Dos lecturas. La hipótesis admite dos preguntas distintas, que se responden por separado: (1) **conteo**, la lectura literal: ¿más de la mitad de los casos son blancos no hispanos?; y (2) **riesgo**: ¿la proporción de personas con CKD es distinta según el grupo étnico? Un grupo puede concentrar la mayoría de los casos solo por ser el más numeroso, sin que la enfermedad sea más frecuente en él.

Utilidad. Distingue el peso de un grupo en el total de casos, útil para dimensionar la atención que requiere, de la frecuencia de la enfermedad dentro del grupo, útil para identificar grupos más afectados.

3.4.2. Estrategia de abordaje

Se trabaja con `poblacion_ckd`; los casos son los adultos con `ckd_clinical` = 1. Las variables son `ethnicity` (cualitativa nominal, 6 grupos) y `ckd_clinical`.

Lectura 1: test Z para una proporción, el mismo de la hipótesis 1, aplicado a los casos. Sea p la proporción de blancos no hispanos entre los adultos con CKD:

- H_0: p = 0,5
- H_1: p > 0,5 (unilateral: «la mayoría» significa más de la mitad, una dirección que surge del enunciado antes de ver los datos)

Lectura 2: test de chi-cuadrado de independencia entre el grupo étnico y la presencia de CKD:

- H_0: el grupo étnico y la presencia de CKD son independientes (la proporción con CKD es la misma en todos los grupos)
- H_1: el grupo étnico y la presencia de CKD no son independientes

Los grados de libertad son (6 − 1) × (2 − 1) = 5, y la condición es que las frecuencias esperadas sean de al menos 5 en todas las celdas. Rechazar H_0 indica que la proporción con CKD no es la

misma en todos los grupos, pero no cuáles difieren: las diferencias se describen con las proporciones de cada grupo y, por el papel de la edad, también por grupo de edad.

3.4.3. Resultados obtenidos y discusión

Grupo étnico	Adultos	% de los adultos	Casos	% de los casos	% con CKD en el grupo	Edad mediana
Blancos no hispanos	3.302	59,2	572	58,8	17,3	60
Negros no hispanos	647	11,6	159	16,4	24,6	52
Otros hispanos	582	10,4	81	8,3	13,9	49,5
Mexicano-americanos	394	7,1	50	5,1	12,7	44
Otro/multirracial	345	6,2	64	6,6	18,6	53
Asiáticos no hispanos	305	5,5	46	4,7	15,1	50
Total	5.575	100	972	100	17,4	—

Tabla 8: Adultos clasificados, casos de CKD y proporción con CKD dentro de cada grupo étnico (notebook, sección 3.4.3).

Lectura 1 (conteo). De los 972 casos, 572 son blancos no hispanos: **58,8 %**, con un intervalo de confianza del 95 % de 55,8 % a 61,9 % (Tabla 8 y Fig. 13). El supuesto se cumple ($n \cdot p_0 = n \cdot (1 - p_0) = 486$). El test da $z = 5{,}52$ y un p-valor menor a 0,001.

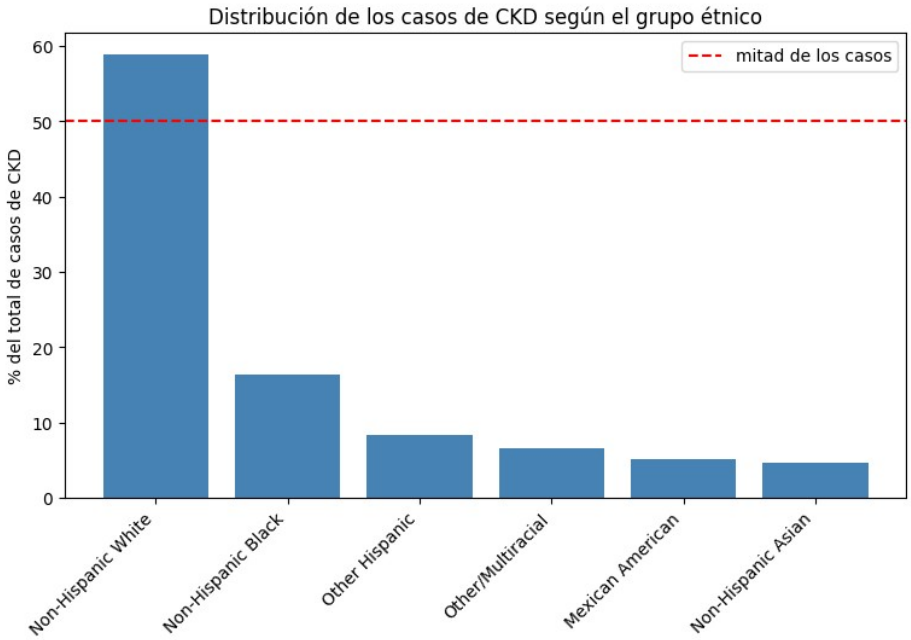


Fig. 13: Porcentaje del total de casos de CKD que corresponde a cada grupo étnico; la línea roja marca la mitad de los casos (notebook, sección 3.4.3).

Lectura 2 (riesgo). El chi-cuadrado da 35,58 con 5 grados de libertad y un p-valor menor a 0,001; la menor frecuencia esperada es 53,2, así que la condición se cumple. La proporción con CKD no es la misma en todos los grupos: va de 12,7 % en los mexicano-americanos a 24,6 % en los

negros no hispanos. En los blancos no hispanos es 17,3 %, prácticamente igual a la de todos los adultos, 17,4 % (Fig. 14).

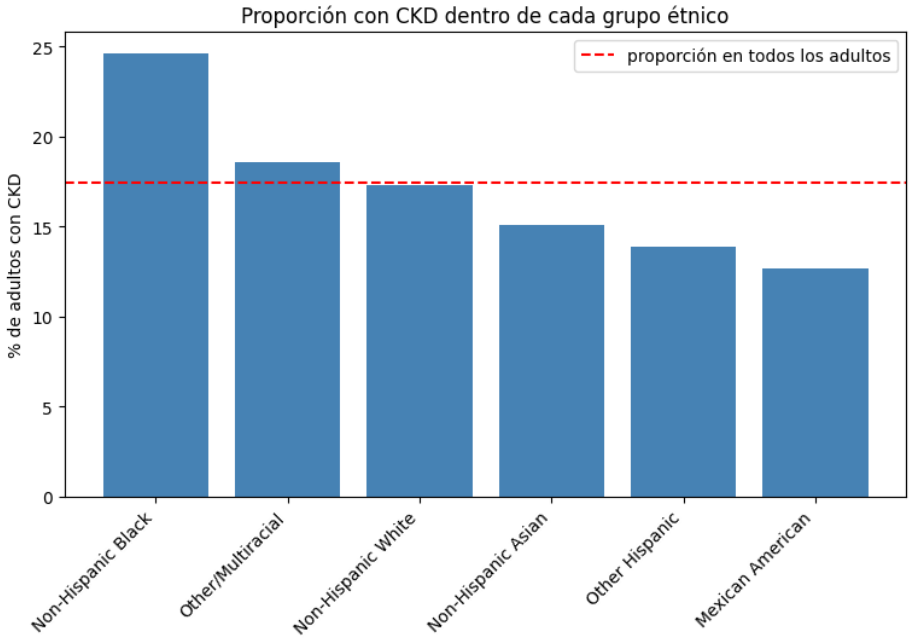


Fig. 14: Proporción de adultos con CKD dentro de cada grupo étnico; la línea roja marca la proporción en todos los adultos (notebook, sección 3.4.3).

Por edad. Los blancos no hispanos tienen una proporción con CKD menor que la del resto de los adultos en los tres grupos de edad: 4,3 % contra 6,9 % de 18 a 39 años, 9,1 % contra 15,3 % de 40 a 59 y 27,4 % contra 30,9 % de 60 o más.

Conclusión: la hipótesis se confirma en su lectura literal: la mayoría de los casos de enfermedad renal crónica (58,8 %) corresponde a blancos no hispanos ($z = 5{,}52$, $p < 0{,}001$). Esa mayoría no refleja una mayor frecuencia de la enfermedad en el grupo: su proporción con CKD (17,3 %) es igual a la del total, menor que la de los negros no hispanos (24,6 %) y menor que la del resto de los adultos en cada grupo de edad.

Discusión. Los blancos no hispanos son el 59,2 % de los adultos analizados, y su participación en los casos (58,8 %) es casi la misma: la mayoría de los casos se explica por cuántos son en la muestra, no por una mayor frecuencia de la enfermedad. Su edad mediana, la más alta (60 años), contribuye a su cantidad de casos; a igual edad, su proporción con CKD es menor que la del resto. El chi-cuadrado indica que el grupo étnico y la enfermedad renal están asociados, pero no qué grupos difieren entre sí, por lo que no se afirma que cada par de grupos difiera significativamente. Como limitaciones, la falta de eGFR varía según el grupo étnico (28,8 % en los blancos no hispanos contra 37,2 % en los negros no hispanos): si los excluidos tuvieran más

enfermedad, los casos de los grupos con más faltantes estarían más subestimados. Además, sin pesos muestrales las proporciones describen a la muestra y no a la población de EE.UU.

Ubicación en el código: *notebook, sección 3.4 (cálculos en 3.4.3).*

3.5. Hipótesis 5 (b): «La presión arterial es un factor de riesgo del CKF»

3.5.1. Definición de la hipótesis

Motivación. La metadata señala a la hipertensión como un factor estrechamente relacionado con el deterioro renal y menciona que los riñones participan en el control de la presión arterial [5]. En el análisis exploratorio, los adultos con eGFR menor a 60 tienen una presión sistólica mediana mayor que el resto, 126 contra 119 mmHg (sección 2.8 de este informe).

Hipótesis. La presión arterial es un factor de riesgo de la enfermedad renal crónica (CKF se interpreta como CKD).

Qué se puede evaluar con estos datos. Un factor de riesgo es una característica que precede a la enfermedad y aumenta la probabilidad de desarrollarla, y demostrarlo requiere seguir a las personas en el tiempo. Con una sola medición por persona se puede evaluar si la presión arterial está **asociada** con la enfermedad renal, una condición necesaria pero no suficiente para que sea un factor de riesgo. La hipótesis se evalúa, entonces, como una diferencia en la presión entre los adultos con y sin CKD. El análisis se centra en la presión sistólica, que en el análisis exploratorio mostró diferencias según la función renal; la diastólica se describe como complemento.

Utilidad. La presión arterial es una medición simple y modificable; establecer su asociación con la enfermedad renal es el primer paso para considerarla en el análisis conjunto de factores de la hipótesis (c).

3.5.2. Estrategia de abordaje

Se comparan los adultos con y sin CKD de `poblacion_ckd` con presión registrada en `bp_systolic` (cuantitativa continua, mmHg). Sean μ_1 y μ_0 las medias de la presión sistólica de los adultos con y sin CKD:

- H_0: $\mu_1 = \mu_0$
- H_1: $\mu_1 \neq \mu_0$ (bilateral)

Se aplica el procedimiento de comparación de dos grupos descrito al inicio de la sección 3, y se describe la presión diastólica de cada grupo. La edad no se ajusta en esta hipótesis: su efecto se discute con los resultados del análisis exploratorio, y el análisis conjunto con otros factores corresponde a la hipótesis (c).

3.5.3. Resultados obtenidos y discusión

De los 5.575 adultos clasificados, 147 no tienen la presión registrada. Los 936 adultos con CKD tienen una presión sistólica media de 130,6 mmHg y una mediana de 128; los 4.492 sin CKD, una media de 120,6 y una mediana de 118 (Fig. 15). Shapiro-Wilk rechaza la normalidad en los dos grupos (estadísticos de 0,978 y 0,965, $p < 0,001$), con un apartamiento concentrado en la cola derecha; con estos tamaños el test t es robusto. Levene rechaza la igualdad de varianzas (estadístico de 151,80, $p < 0,001$; desvíos de 22,9 y 16,6 mmHg), por lo que se usa el test t de Welch: $t = 12,62$, $p < 0,001$, con una diferencia de medias de 9,95 mmHg. El control de Kruskal-Wallis coincide (estadístico de 171,97, $p < 0,001$). La presión diastólica no muestra diferencias entre los grupos: mediana de 74 mmHg en ambos y medias de 75,4 y 74,9.

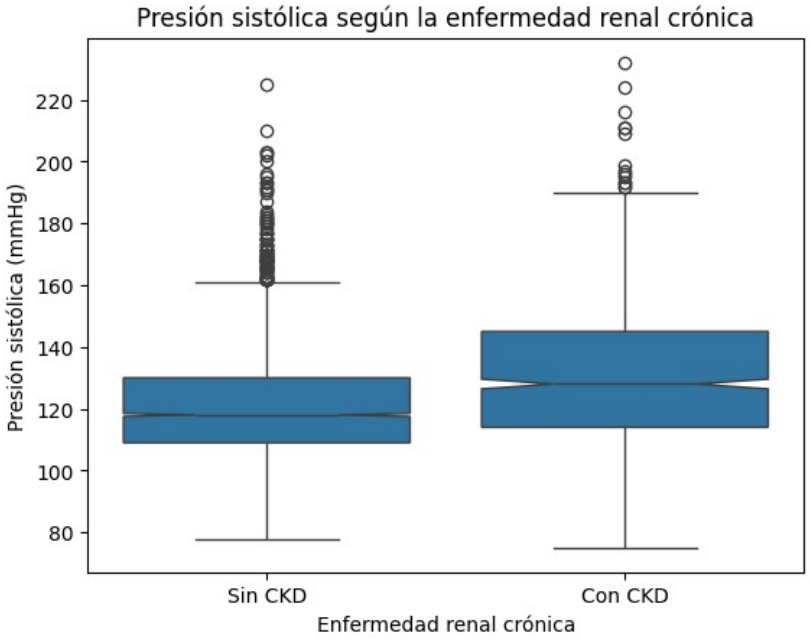


Fig. 15: Presión sistólica de los adultos sin y con enfermedad renal crónica (criterio clínico); las muescas marcan el intervalo de confianza de la mediana (notebook, sección 3.5.3).

Conclusión: se rechaza H_0. La presión sistólica es significativamente mayor en los adultos con enfermedad renal crónica (media de 130,6 contra 120,6 mmHg, unos 10 mmHg más). La hipótesis se confirma como asociación: con estos datos no se puede establecer que la presión arterial sea un factor de riesgo, es decir, que preceda a la enfermedad y aumente la probabilidad de desarrollarla.

Discusión. La diferencia es de unos 10 mmHg tanto en la media como en la mediana, y el grupo con CKD tiene además más dispersión (desvío de 22,9 contra 16,6 mmHg), es decir, más valores altos. Los adultos con CKD son mayores (mediana de 68 contra 52 años), y la presión sistólica aumenta con la edad: en el análisis exploratorio su mediana pasa de 112 mmHg entre los 18 y 39

años a 127 mmHg a partir de los 60. Parte de la diferencia puede deberse a la edad; esta hipótesis no la ajusta, y el análisis conjunto corresponde a la hipótesis (c). En cuanto a la dirección de la relación, los riñones participan en el control de la presión arterial [5], así que la enfermedad renal también puede elevarla, y con una sola medición por persona no se puede distinguir si la presión alta precede a la enfermedad o es una consecuencia. El archivo no tiene datos de tratamiento antihipertensivo, lo que tiende a reducir la diferencia observada, y trae un solo valor de las tres lecturas que toma NHANES, sin indicar cuál [P20]. La falta de diferencia en la diastólica es coherente con la mayor edad del grupo con CKD: con la edad, la rigidez de las arterias tiende a elevar la presión sistólica más que la diastólica.

Ubicación en el código: *notebook, sección 3.5 (cálculos en 3.5.3).*

3.6. Hipótesis 6 (c): «Existe un vínculo directo entre la edad, sexo, BMI, presión arterial, diabetes, tabaquismo y nivel socioeconómico con la probabilidad de presentar CKD»

3.6.1. Definición de la hipótesis

Motivación. La metadata señala que la diabetes y la hipertensión son factores estrechamente relacionados con el deterioro renal, y que también importan la edad, el tabaquismo, el exceso de peso y las condiciones socioeconómicas [5]. Las hipótesis anteriores muestran que esas variables no son independientes entre sí: por ejemplo, la presión sistólica es más alta en los adultos con CKD, pero ese grupo también es mayor. Para saber qué variables se vinculan con la enfermedad por sí mismas, hay que analizarlas en conjunto.

Hipótesis. Existe un vínculo directo entre la edad, el sexo, el BMI, la presión arterial, la diabetes, el tabaquismo y el nivel socioeconómico con la probabilidad de presentar CKD.

Interpretación de los términos:

- **Vínculo directo:** asociación de cada variable con la probabilidad de CKD manteniendo constantes las otras seis. Una variable puede asociarse con la CKD solo porque acompaña a otra (por ejemplo, a la edad); en ese caso no tiene un vínculo directo.
- **Nivel socioeconómico:** el índice de pobreza (`poverty_income_ratio`), el ingreso del hogar dividido por el umbral de pobreza.
- **Presión arterial:** la presión sistólica, con el mismo criterio que la hipótesis (b). **Diabetes:** `diabetes_status` (sin diabetes, borderline o diagnosticada). **Tabaquismo:** `smoking_status` (nunca fumó, ex fumador o fumador actual).
- Como en la hipótesis (b), con una sola medición por persona se evalúa asociación y no causalidad.

Utilidad. Identifica qué factores conservan un vínculo con la enfermedad renal cuando se los considera en conjunto, y completa el análisis de la presión arterial de la hipótesis (b), que no tenía en cuenta la edad.

3.6.2. Estrategia de abordaje

Se ajusta una **regresión logística múltiple** sobre los adultos de `poblacion_ckd` con datos en las siete variables (casos completos). La variable respuesta, `ckd_clinical`, es binaria, y la hipótesis se refiere a la probabilidad de presentar CKD: la regresión logística modela esa probabilidad con una función de los predictores que siempre toma valores entre 0 y 1, mientras que una regresión lineal sobre una variable 0/1 podría dar valores fuera de ese rango. Los coeficientes se estiman por máxima verosimilitud. Manteniendo constantes los demás predictores, un coeficiente positivo indica que la probabilidad de CKD aumenta cuando el predictor aumenta, y uno negativo, que disminuye. La Tabla 9 detalla las variables y su codificación.

Variable del enunciado	Columna	Tipo	Codificación en el modelo
Probabilidad de CKD (respuesta)	`ckd_clinical`	binaria	0/1 (1 = con CKD)
Edad	`age`	cuantitativa continua (años)	estandarizada
Sexo	`gender`	binaria	`hombre`: 1 hombre, 0 mujer (referencia)
BMI	`bmi`	cuantitativa continua (kg/m^2)	estandarizada
Presión arterial	`bp_systolic`	cuantitativa continua (mmHg)	estandarizada
Diabetes	`diabetes_status`	cualitativa ordinal, 3 categorías	`diabetes_borderline` y `diabetes_diagnosticada` (0/1); referencia: sin diabetes
Tabaquismo	`smoking_status`	cualitativa, 3 categorías	`ex_fumador` y `fumador_actual` (0/1); referencia: nunca fumó
Nivel socioeconómico	`poverty_income_ratio`	cuantitativa continua (índice)	estandarizada

Tabla 9: Variables del modelo logístico de la hipótesis (c), con su tipo y su codificación (notebook, sección 3.6.2).

Cada columna 0/1 compara su categoría con la de referencia. Ingresar la diabetes o el tabaquismo como un único número (0, 1, 2) supondría que el paso de una categoría a la siguiente tiene siempre el mismo efecto; y la categoría de referencia no lleva columna porque las tres columnas sumarían siempre 1, igual que la constante, y los coeficientes no podrían estimarse (multicolinealidad perfecta). Para cada predictor:

- H_0: $\beta_j = 0$ (a igualdad de las demás variables, el predictor no se vincula con la probabilidad de CKD)
- H_1: $\beta_j \neq 0$ (bilateral)

Se usa el test z de cada coeficiente. La significancia global se evalúa con el test de razón de verosimilitud, que compara el modelo con uno sin predictores, y como medida descriptiva del ajuste se informa el pseudo R^2 de McFadden. Una variable tiene vínculo directo si su coeficiente es significativo (en la diabetes y el tabaquismo, si lo es al menos una de sus categorías); la hipótesis se confirma por completo si las siete variables tienen vínculo directo, y en parte si solo algunas lo tienen. Supuestos: observaciones independientes, ausencia de multicolinealidad fuerte (correlaciones y VIF) y cantidad suficiente de casos por predictor; la regresión logística no requiere residuos normales ni varianzas iguales.

3.6.3. Resultados obtenidos y discusión

De los 5.575 adultos clasificados, 4.698 tienen las siete variables, 778 con CKD (16,6 %). Se excluyen 877 adultos (15,7 %), sobre todo por el índice de pobreza (713 sin dato); faltan además 147 valores de presión, 61 de BMI, 9 de tabaquismo y 1 de diabetes. Las medianas con y sin CKD son de 68 contra 53 años de edad, 29,7 contra 28,0 de BMI, 128 contra 119 mmHg de presión sistólica y 2,4 contra 3,0 de índice de pobreza. La proporción con CKD es de 15,9 % en las mujeres y 17,3 % en los hombres; 12,6 % sin diabetes, 21,6 % con diabetes borderline y 40,4 % con diabetes diagnosticada; y 13,7 % en quienes nunca fumaron, 22,3 % en los ex fumadores y 18,0 % en los fumadores actuales.

La correlación más alta entre los predictores es la de la edad con la presión sistólica (0,38), y los VIF van de 1,024 a 1,303: no hay multicolinealidad fuerte. Hay 778 casos para 9 predictores, unos 86 casos por predictor. El modelo es significativo en conjunto (estadístico de razón de verosimilitud de 675,7, $p < 0,001$), con un pseudo R^2 de 0,160. La Tabla 10 y la Fig. 16 presentan los coeficientes: los intervalos de los cinco significativos no incluyen el 0, y los de los cuatro no significativos sí lo incluyen.

Variable	Coeficiente	IC 95 %	Qué compara	p-valor	Vínculo directo
Edad	0,809	0,694 a 0,924	un desvío (17,8 años); 0,045 por año	< 0,001	Sí
Presión sistólica	0,276	0,195 a 0,357	un desvío (18,1 mmHg); 0,015 por mmHg	< 0,001	Sí
Índice de pobreza	−0,280	−0,370 a −0,191	un desvío (1,65); −0,170 por unidad	< 0,001	Sí
BMI	0,168	0,082 a 0,254	un desvío (7,1 kg/m^2); 0,024 por kg/m^2	< 0,001	Sí
Diabetes diagnosticada	1,030	0,827 a 1,234	frente a sin diabetes	< 0,001	Sí
Diabetes borderline	0,139	−0,270 a 0,549	frente a sin diabetes	0,505	No
Ex fumador	0,160	−0,031 a 0,350	frente a nunca fumó	0,100	No
Fumador actual	0,115	−0,135 a 0,364	frente a nunca fumó	0,369	No
Hombre	0,050	−0,120 a 0,221	frente a mujer	0,565	No

Tabla 10: Coeficientes del modelo logístico, con su intervalo de confianza del 95 % y lo que compara cada uno (notebook, sección 3.6.3).

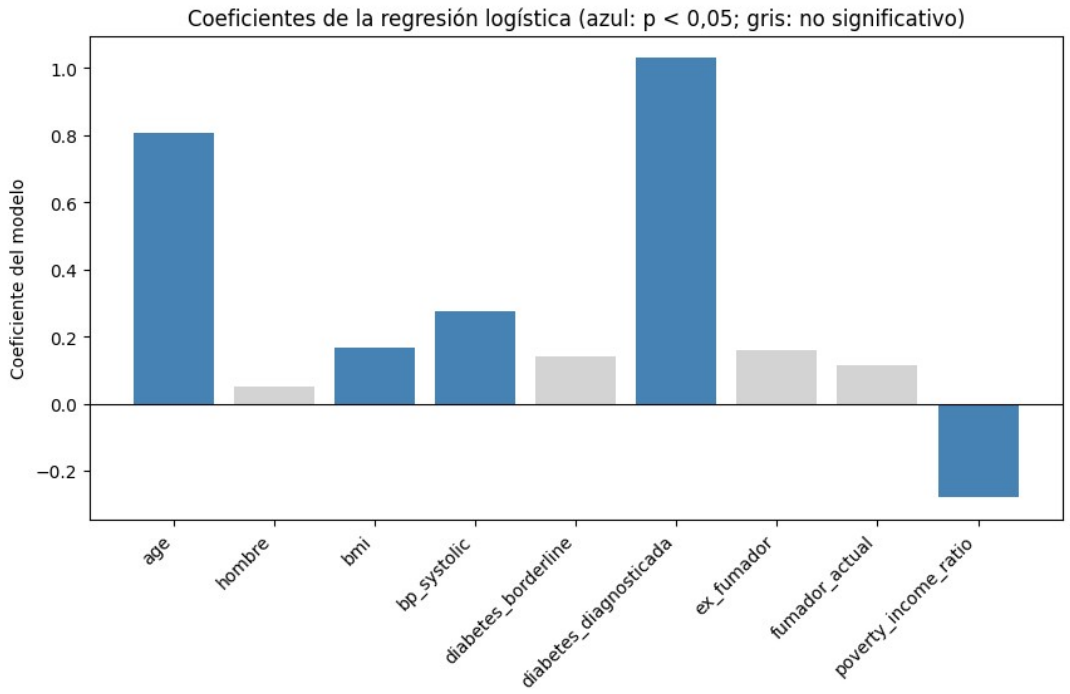


Fig. 16: Coeficientes de la regresión logística: en azul, los significativos (p < 0,05); en gris, los no significativos (notebook, sección 3.6.3).

Conclusión: la hipótesis se confirma en parte. A igualdad de las demás variables, la edad, el BMI, la presión arterial sistólica, la diabetes diagnosticada y el nivel socioeconómico tienen un vínculo directo y significativo con la probabilidad de presentar enfermedad renal crónica: la probabilidad aumenta con la edad, el BMI y la presión, es mayor con diabetes diagnosticada y

disminuye cuando aumenta el ingreso del hogar. El sexo y el tabaquismo no tienen un vínculo directo significativo.

Discusión.

- **Fuerza de los vínculos.** Entre los predictores cuantitativos, un desvío de edad (0,81) pesa casi el triple que un desvío de presión sistólica (0,28) o de índice de pobreza (−0,28), y unas cinco veces más que un desvío de BMI (0,17). La diabetes diagnosticada tiene el coeficiente más alto del modelo (1,03), aunque esa comparación es aproximada: contrasta el paso de una categoría a otra con el aumento de un desvío.
- **Edad.** Parte de su vínculo se explica por la propia definición: el eGFR, uno de los dos criterios de la CKD, se calcula con una ecuación que incluye la edad [4], así que, con la misma creatinina, un adulto mayor obtiene un eGFR más bajo. Además, la edad está censurada en 80 años [P8].
- **Presión arterial.** Conserva un vínculo significativo al considerar la edad y las demás variables: la diferencia de la hipótesis (b) no se explica solo por la edad. Sigue siendo una asociación, con las salvedades de esa hipótesis sobre la dirección de la relación y la falta de datos de medicación.
- **Diabetes.** La diabetes diagnosticada tiene un vínculo claro. La borderline no: su mayor proporción de CKD (21,6 % contra 12,6 %) se explica por las otras variables, y con 162 adultos su estimación es poco precisa.
- **Tabaquismo.** Sin ajustar, los ex fumadores tienen más CKD que quienes nunca fumaron (22,3 % contra 13,7 %), pero el vínculo no es significativo al considerar las demás variables. Los ex fumadores son, en promedio, mayores (correlación de 0,23 con la edad), así que la diferencia sin ajustar refleja sobre todo otras características del grupo: es un ejemplo de asociación sin vínculo directo. El tabaquismo, además, es autodeclarado.
- **Sexo.** La proporción con CKD es parecida en hombres y mujeres (17,3 % contra 15,9 %), y el sexo no tiene un vínculo directo.
- **Nivel socioeconómico.** A igualdad de las demás variables, un menor ingreso del hogar se vincula con una mayor probabilidad de CKD. El índice falta en 713 adultos, su falta varía según el grupo étnico [P11] y está censurado en 5 [P10]: si los adultos excluidos difirieran en su salud renal, la estimación podría estar sesgada.
- **Ajuste y limitaciones.** El pseudo R^2 de 0,16 indica que las siete variables explican una parte limitada de la presencia de CKD: el modelo se usa para evaluar vínculos, no para predecir casos individuales. Se analizan los casos completos, y los 877 adultos excluidos pueden diferir de los incluidos. El modelo supone que el efecto de cada predictor cuantitativo es el mismo en todo su rango, algo que no se verificó. Con una sola medición por persona y sin pesos muestrales [P25], los resultados son asociaciones que describen a la muestra.

Ubicación en el código: *notebook, sección 3.6 (cálculos en 3.6.3).*

4. Conclusiones

4.1. Resumen de las hipótesis

El trabajo partió de un archivo derivado de NHANES con problemas de codificación, de clasificación renal y de diseño (sección 1). Una vez construido un criterio clínico de enfermedad renal y definidas las poblaciones de análisis (sección 2), se validaron seis hipótesis, cuyos resultados resume la Tabla 11 (notebook, sección 4).

Sección	Hipótesis	Técnica	Resultado principal	¿Se confirma?
3.1	La proporción de adultos con CKD difiere del 14 % estimado por el CDC	Test Z para una proporción (bilateral) e intervalo de confianza del 95 %	17,4 % (IC 95 %: 16,4 % a 18,4 %); z = 7,39, p < 0,001	Sí: la proporción de la muestra es mayor
3.2	El ácido úrico difiere entre los adultos con y sin CKD	Test t de Welch, con Kruskal-Wallis como control	Media de 5,65 contra 5,05 mg/dL; t = 10,81, p < 0,001	Sí
3.3	La diferencia de ácido úrico se mantiene a igualdad de edad, sexo y BMI	Regresión lineal múltiple, con Kruskal-Wallis por sexo y edad como control	0,46 mg/dL (IC 95 %: 0,38 a 0,55) frente a 0,60 sin ajustar; t = 10,32, p < 0,001	Sí; supuestos de normalidad y homocedasticidad cumplidos en parte
3.4 (a)	La mayoría de los casos de CKD corresponde a blancos no hispanos	Test Z para una proporción (unilateral) y chi-cuadrado de independencia	58,8 % de los casos (z = 5,52, p < 0,001); proporción con CKD en el grupo de 17,3 %, prácticamente igual a la del total (17,4 %)	Sí en su lectura literal; no refleja un mayor riesgo
3.5 (b)	La presión arterial es un factor de riesgo de la CKD	Test t de Welch, con Kruskal-Wallis como control	Presión sistólica media de 130,6 contra 120,6 mmHg; t = 12,62, p < 0,001	Como asociación; no puede establecerse como factor de riesgo
3.6 (c)	Vínculo directo de la edad, el sexo, el BMI, la presión arterial, la diabetes, el tabaquismo y el nivel socioeconómico con la probabilidad de CKD	Regresión logística múltiple	Vínculo directo de la edad, el BMI, la presión sistólica, la diabetes diagnosticada y el índice de pobreza; sin vínculo del sexo ni del tabaquismo	En parte: cinco de las siete variables

Tabla 11: Resumen de las seis hipótesis: técnica, resultado principal y decisión (notebook, sección 4).

4.2. Hallazgos transversales

Más allá de cada hipótesis, el análisis deja seis hallazgos que las atraviesan:

1. **La definición de CKD cambia todo.** Con la regla del archivo, el 46,8 % de los 5.658 adultos con eGFR tendría CKD; con el criterio clínico, la tiene el 17,4 % de los 5.575 adultos clasificados. Antes de cualquier test, la decisión sobre cómo definir la enfermedad determina qué se estudia (secciones 2.6 y 2.10).
2. **La edad atraviesa todas las hipótesis.** Contribuye a que la prevalencia de la muestra supere la estimación del CDC, por el sobremuestreo de las edades avanzadas (3.1); los adultos con CKD son mayores (mediana de 68 contra 52 años) en las hipótesis 2 y (b); los blancos no hispanos son el grupo de mayor edad mediana (3.4); y en la hipótesis (c) la edad

es el predictor cuantitativo de mayor coeficiente, en parte por construcción del eGFR, mientras que el tabaquismo, más frecuente entre los ex fumadores de mayor edad, deja de tener un vínculo significativo al considerar todas las variables.

3. **Contar casos no es medir riesgo.** Los blancos no hispanos concentran el 58,8 % de los casos, pero su proporción con CKD (17,3 %) es igual a la del total y menor que la del resto en cada grupo de edad: la mayoría de los casos se explica sobre todo por su peso en la muestra (59,2 % de los adultos) (3.4).
4. **La CKD tiene dos caras.** Entre los casos de 18 a 39 años, solo el 1,1 % tiene eGFR menor a 60: la enfermedad se define casi siempre por la albuminuria. Entre los de 60 años o más, el 59,7 % tiene el filtrado disminuido. La diferencia de ácido úrico aparece donde predomina el filtrado disminuido, lo que se interpreta como coherente con su eliminación por los riñones (3.3).
5. **El nivel socioeconómico importa.** A igualdad de edad, sexo, BMI, presión, diabetes y tabaquismo, un menor ingreso del hogar se vincula con una mayor probabilidad de CKD (coeficiente de −0,280 por desvío del índice de pobreza), con la salvedad de que el ingreso falta en 713 adultos y no al azar (3.6).
6. **Asociación no es causa.** NHANES es un estudio transversal con una sola medición por persona: todos los vínculos encontrados, incluido el de la presión arterial, son asociaciones, y ninguno permite afirmar que una variable preceda a la enfermedad o la cause (3.5).

4.3. Limitaciones

- **Muestra sin pesos muestrales [P25].** Los resultados describen a la muestra y no a la población de EE.UU.; además, el ciclo sobremuestrea por grupo de edad.
- **Una sola medición por persona.** No se puede confirmar la persistencia de tres meses que exige la definición de CKD ni el orden temporal entre las variables: todos los resultados son asociaciones.
- **Adultos sin clasificar.** Quedan fuera de los análisis renales 2.495 adultos sin eGFR y 83 sin ACR, y la falta de eGFR varía según el grupo étnico.
- **Faltantes que no son al azar.** El índice de pobreza falta en 713 de los adultos clasificados y su falta varía según el grupo étnico [P11]; la hipótesis (c) usa solo los casos completos.
- **Mediciones.** La presión es una sola lectura sin indicar cuál [P20] y no hay datos de medicación; la edad y el índice de pobreza están censurados en 80 y 5 [P8] [P10]; el eGFR incluye la edad y el sexo en su ecuación [4].
- **Diseño muestral complejo.** Las observaciones no son completamente independientes, como suponen los tests utilizados.

- **Tamaño de la muestra.** Con miles de observaciones, diferencias pequeñas resultan significativas: por eso cada hipótesis informa la magnitud de la diferencia además del p-valor.

Referencias

1. National Center for Health Statistics. NHANES August 2021–August 2023. https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/default.aspx?Cycle=2021-2023

2. CKD-NHANES 2021-2023: Staged Kidney Disease [dataset]. Kaggle. https://www.kaggle.com/datasets/alitaqishah/ckd-nhanes-2021-2023-staged-kidney-disease

3. National Center for Health Statistics. Demographic Variables and Sample Weights (DEMO_L). https://wwwn.cdc.gov/Nchs/Data/Nhanes/Public/2021/DataFiles/DEMO_L.htm

4. Inker LA, Eneanya ND, Coresh J, et al. New Creatinine- and Cystatin C–Based Equations to Estimate GFR without Race. N Engl J Med 2021;385:1737-1749. https://pubmed.ncbi.nlm.nih.gov/34554658

5. metadata.docx: diccionario de variables que acompaña al conjunto de datos CKD_NHANES_2021_2023.csv.

6. National Center for Health Statistics. NHANES August 2021–August 2023 Response Rates. https://wwwn.cdc.gov/nchs/data/ResponseRates/NHANES-August-2021-August-2023-Response-Rates.pdf

7. KDIGO. CKD Evaluation and Management Guideline. https://kdigo.org/guidelines/ckd-evaluation-and-management/

8. National Center for Health Statistics. Blood Pressure – Oscillometric Measurement (BPXO_L). https://wwwn.cdc.gov/Nchs/Data/Nhanes/Public/2021/DataFiles/BPXO_L.htm

9. National Center for Health Statistics. Albumin & Creatinine – Urine (ALB_CR_L). https://wwwn.cdc.gov/Nchs/Data/Nhanes/Public/2021/DataFiles/ALB_CR_L.htm

10. Centers for Disease Control and Prevention. Chronic Kidney Disease in the United States (2026). https://www.cdc.gov/kidney-disease/media/pdfs/CKD-Factsheet-H.pdf